Codage Binaire des Chiffres Décimaux : Format Fixe, Format Variable et Levée d'Ambiguïté par Codes Auto-délimités

Thème principal : Architecture & Bas Niveau — Représentation et Codage des Données

Synthèse exécutive : Ce cours traite de la représentation binaire des chiffres décimaux (de 0 à 9) destinés à être assemblés par concaténation pour former de grands nombres (ex: le nombre 123 est représenté par la juxtaposition du code de 1, du code de 2 et du code de 3). Nous comparons deux approches fondamentales de codage : le Format Fixe et le Format Variable. En Format Fixe, l'équation 2^N >= 10 impose N = 4 bits par chiffre, garantissant un découpage trivial à la réception mais générant du gaspillage mémoire. En Format Variable brut, l'équation 2^(N_max+1) - 2 >= 10 montre qu'une longueur maximale N_max = 3 bits suffit théoriquement ; toutefois, ce format détruit les frontières de mots et rend le flux ambigu (« la machine réceptrice est comme un couillon » car elle ne peut pas décider de la découpe). Enfin, nous démontrons comment les codes à longueur variable auto-délimités (utilisant une règle de rupture syntaxique) permettent d'obtenir une longueur moyenne de 3,8 bits par chiffre (gain de 5% par rapport au format fixe) tout en garantissant un décodage parfait et non ambigu à la volée.

1. Représentation des Nombres Décimaux par Concaténation Binaire

Pour représenter de grands nombres décimaux dans les systèmes informatiques, une approche directe consiste à coder individuellement chaque chiffre de l'alphabet décimal (les 10 symboles de 0 à 9) sous la forme d'un mot binaire, puis à concaténer (juxtaposer) ces mots. En base 10, le nombre '123' est formé par le chiffre 1, suivi du chiffre 2, puis du chiffre 3. En binaire, le principe est strictement identique : on remplace le chiffre '1' par son code binaire, le '2' par son code binaire, et le '3' par son code binaire. La concaténation de ces trois blocs forme la séquence binaire complète transmise ou stockée. L'enjeu central est de définir la longueur optimale des mots binaires associés aux chiffres afin de réduire le volume de données tout en permettant au système récepteur de retrouver sans ambiguïté les chiffres initiaux lors du décodage du flux continu.

- Concaténation binaire : Assemblage séquentiel des mots binaires codant chaque chiffre d'un nombre décimal.
- Poids positionnel : Préservation stricte de l'ordre d'origine des chiffres pour reconstruire la valeur numérique exacte.

Cas concret enseignant : *L'enseignant illustre le principe avec le nombre 123 : en décimal, c'est la juxtaposition des symboles '1', '2' et '3'. En binaire, si le 1 possède un code binaire donné, le 2 son code, et le 3 son code, coller ces trois mots bout à bout génère la représentation du nombre 123.*

2. Analyse Mathématique Comparée : Format Fixe vs Format Variable Brut

Pour coder M = 10 symboles distincts (les chiffres décimaux de 0 à 9) avec un alphabet binaire de taille 2 : - **En Format Fixe** : La capacité totale d'adressage avec N bits est 2^N. Nous cherchons le plus petit entier N respectant 2^N >= 10. * Pour N = 3 : 2^3 = 8 < 10 (insuffisant). * Pour N = 4 : 2^4 = 16 >= 10 (valide). Le format fixe nécessite donc obligatoirement **4 bits par chiffre**. - **En Format Variable** : On cumule l'ensemble des combinaisons possibles offertes par les mots de longueur 1 bit, de longueur 2 bits, jusqu'à la longueur maximale N_max bits. La capacité totale est la somme géométrique 2^1 + 2^2 + ... + 2^N_max = 2^(N_max+1) - 2. Nous cherchons le plus petit N_max tel que 2^(N_max+1) - 2 >= 10. * Pour N_max = 2 : 2^3 - 2 = 6 < 10 (insuffisant). * Pour N_max = 3 : 2^4 - 2 = 14 >= 10 (valide). En format variable, la longueur maximale requise n'est que de **3 bits**, prouvant qu'en théorie ce format offre une compacité supérieure.

- Format Fixe : Tous les mots binaires ont la même longueur N bits. Formule de capacité : 2^N >= M.
- Format Variable : Les mots binaires ont des longueurs différentes. Formule de capacité : Sum(2^k pour k de 1 à N_max) = 2^(N_max+1) - 2 >= M.
- Cardinalité de l'alphabet : En binaire, la taille de l'alphabet est |L| = 2 (symboles 0 et 1).

Cas concret enseignant : *Le professeur démontre la formule au tableau : avec N_max = 3, on dispose de 2 mots de 1 bit (0, 1), 4 mots de 2 bits (00, 01, 10, 11) et 8 mots de 3 bits (000 à 111), soit un total de 2 + 4 + 8 = 14 combinaisons, ce qui suffit amplement pour loger nos 10 chiffres décimaux.*

3. Le Problème de l'Ambiguïté et du Découpage (Framing)

L'avantage déterminant du format fixe réside dans la simplicité absolue du découpage : sachant que chaque chiffre occupe exactement 4 bits, la machine réceptrice découpe le flux continu reçu par tranches de 4 bits (bits 1 à 4 = premier chiffre, bits 5 à 8 = deuxième chiffre, etc.). À l'inverse, le format variable brut (sans délimiteur) crée une perte totale des frontières entre mots binaires. Lorsqu'une suite de bits arrive au récepteur, plusieurs découpages arbitraires deviennent compatibles avec la même séquence. Le message n'est plus déterministe et devient inutilisable pour le traitement informatique.

- Framing / Découpage : Capacité du récepteur à identifier sans ambiguïté les limites de chaque mot binaire dans un flux continu.
- Ambiguïté de décodage : Incertitude sur l'interprétation d'une suite binaire due à la perte des frontières des mots.

Cas concret enseignant : *Le professeur insiste avec une métaphore marquante : si l'on transmet un flux variable codant 123 sans délimiteur, à la réception le processeur « est comme un couillon ». En effet, le même flux de bits reçu peut être interprété comme le nombre 123, mais tout autant comme 1212 ou comme 33, car la machine ne sait pas où couper.*

4. Levée d'Ambiguïté : Codes Auto-délimités et Calcul de Longueur Moyenne

Pour concilier la compacité du format variable et le décodage déterministe du format fixe, on construit des codes auto-délimités en imposant une règle structurelle de rupture. Exemple de règle : *« Dès que le motif '10' est rencontré dans le mot, le mot s'arrête immédiatement après le bit suivant (avec une longueur maximale autorisée de 5 bits) »*. En appliquant une telle règle pour générer 10 mots binaires uniques correspondant aux 10 chiffres décimaux, le dictionnaire de mots généré présente des longueurs variées. Si la somme totale des longueurs des 10 mots de ce dictionnaire s'élève à 38 bits, la longueur moyenne statistique par chiffre est : L_moyen = 38 / 10 = 3,8 bits par chiffre. Comparaison avec le format fixe (4 bits) : - Format Fixe = 4,0 bits/chiffre. - Format Variable Auto-délimité = 3,8 bits/chiffre. - Gain de compacité = (4 - 3,8) / 4 = 5% d'économie d'espace et de bande passante, tout en conservant un décodage 100% garanti et sans ambiguïté.

- Règle de rupture / d'arrêt : Condition syntaxique imposée au mot binaire indiquant immédiatement sa fin au récepteur.
- Code auto-délimité (Code préfixe) : Code à longueur variable conçu pour que la fin de chaque mot soit détectée sans séparateur externe.
- Longueur moyenne (L_moyen) : Somme de toutes les longueurs de mots du dictionnaire divisée par le nombre total de symboles.

Cas concret enseignant : *L'enseignant fait calculer aux étudiants la somme des longueurs des 10 mots créés par la règle : 5 + 10 + 15 + ... = 38 bits au total. Divisé par 10 chiffres, cela donne 3,8 bits/chiffre. Il conclut : « Même si c'est légèrement plus long que le format variable brut (3 bits), on bat le format fixe de 4 bits avec 5% de gain, tout en sachant parfaitement décoder à la volée ! »*

■ Questions & Interventions des Étudiants en Classe

Question étudiant : Quel est l'intérêt de conserver le format fixe si le format variable permet d'avoir des mots d'une longueur maximale plus courte ?
Réponse du professeur : Le format fixe simplifie drastiquement le matériel et l'algorithme de décodage : le récepteur découpe aveuglément le flux par tranches régulières de N bits (ex: 4 bits). En format variable brut, la longueur plus courte n'a aucune valeur si la machine est incapable de déterminer où finit un symbole et où commence le suivant.

Question étudiant : Pourquoi dans la règle de délimitation ('dès qu'on rencontre 10, on s'arrête au bit suivant'), le 3ème cas s'arrête-t-il à un endroit spécifique ?
Réponse du professeur : C'est la règle de rupture elle-même qui dicte l'arrêt exact. Dès que la séquence '10' est lue par le récepteur, l'automate sait qu'il doit consommer un ultime bit pour compléter le mot en cours, fixant ainsi de manière déterministe la frontière du symbole sans avoir besoin de bit de séparation supplémentaire.

■ Exercice & Démonstration d'Application

Énoncé : 1. Calculer le nombre de bits minimal N requis pour coder les M = 10 chiffres décimaux (0 à 9) en Format Fixe. 2. Calculer la longueur maximale N_max requise en Format Variable brut. 3. Soit un code binaire auto-délimité assignant aux 10 chiffres décimaux des mots de longueurs respectives [2, 3, 3, 4, 4, 4, 4, 4, 5, 5] bits. Calculer la longueur moyenne par chiffre ainsi que le pourcentage de gain de stockage obtenu par rapport au format fixe.

Résolution pas à pas :
1. **Format Fixe** : Condition : 2^N >= 10 - Pour N = 3 : 2^3 = 8 < 10 (insuffisant) - Pour N = 4 : 2^4 = 16 >= 10 (valide) Résultat : N = 4 bits par chiffre. 2. **Format Variable Brut** : Condition : Sum(2^k pour k de 1 à N_max) = 2^(N_max + 1) - 2 >= 10 - Pour N_max = 2 : 2^(2+1) - 2 = 8 - 2 = 6 < 10 (insuffisant) - Pour N_max = 3 : 2^(3+1) - 2 = 16 - 2 = 14 >= 10 (valide) Résultat : N_max = 3 bits. 3. **Longueur moyenne et Gain** : - Somme des longueurs = 2 + 3 + 3 + 4 + 4 + 4 + 4 + 4 + 5 + 5 = 38 bits au total. - Longueur moyenne L_moyen = 38 / 10 = 3,8 bits par chiffre. - Gain relatif par rapport au format fixe (4 bits) : Gain = (4 - 3,8) / 4 = 0,2 / 4 = 0,05 = 5%.

Résultat : Format fixe : 4 bits/chiffre | Format variable brut max : 3 bits | Format variable auto-délimité : 3,8 bits/chiffre en moyenne (Gain de 5% de bande passante avec garantie de décodage non ambigu).

■ Auto-Évaluation Flash d'Examen

Q : Quelle est la condition mathématique permettant d'établir le nombre de bits N en format fixe pour encoder M symboles distincts ?

R : La condition est 2^N >= M, où N est le nombre de bits fixe et M le nombre de symboles à coder.

Q : Pourquoi la formule de capacité du format variable de longueur maximale N_max s'écrit-elle 2^(N_max + 1) - 2 ?

R : Parce qu'elle représente la somme géométrique des combinaisons offertes par chaque longueur de mot k (de 1 à N_max) : Sum(2^k) = 2^1 + 2^2 + ... + 2^N_max = 2^(N_max + 1) - 2.

Q : Quel est le risque majeur d'un codage en format variable brut ne possédant aucune règle de délimitation ?

R : Le risque majeur est l'ambiguïté au décodage : le récepteur reçoit un flux continu de bits sans savoir où couper les mots, rendant le message récepteur totalement indécidable.