Codage Binaire des Chiffres Décimaux : Format Fixe, Format Variable et Levée d'Ambiguïté par Codes Auto-délimités

Thème principal : Représentation et Codage de l'Information : Concaténation, Framing et Optimisation de Longueur de Code

Synthèse exécutive : Ce cours traite de la représentation binaire des nombres décimaux en encodant séparément chaque chiffre (de 0 à 9) avant de les concaténer. Deux approches fondamentales sont analysées : le Format Fixe et le Format Variable. En Format Fixe, la contrainte 2^N >= 10 impose N = 4 bits par chiffre, garantissant un découpage (framing) immédiat mais sous-optimal en mémoire. En Format Variable Brut, la somme géométrique des capacités montre qu'une longueur maximale N_max = 3 bits suffit théoriquement ; toutefois, ce format détruit les frontières de mots et rend le message totalement ambigu au décodage (« le récepteur est comme un couillon »). Pour surmonter ce blocage, le cours introduit les codes à longueur variable auto-délimités fondés sur une règle syntaxique de rupture (ex: arrêt après le motif '10'). Cette méthode permet de concilier un découpage univoque à la volée avec une longueur moyenne de 3,8 bits par chiffre, réalisant un gain de compacité de 5% par rapport au format fixe.

1. Principe de Codage par Concaténation de Chiffres Décimaux

Pour représenter de grands nombres décimaux dans les systèmes informatiques, l'une des approches les plus naturelles consiste à ne pas coder le nombre entier directement, mais à encoder individuellement chaque chiffre de l'alphabet décimal (de 0 à 9) sous la forme d'un 'mot binaire', puis à juxtaposer (concaténer) ces mots binaires. C'est le principe exact de la numération de position en base 10 : pour écrire le nombre '123', on juxtaposera le symbole '1', le symbole '2', puis le symbole '3'. Transposé en binaire, si le chiffre 1 possède un mot binaire associé C(1), le chiffre 2 un mot C(2), et le 3 un mot C(3), la représentation du nombre 123 sera le bloc binaire continu C(1)C(2)C(3). L'enjeu technique fondamental réside dans la détermination de la longueur de ces mots binaires : comment réduire le volume de bits stockés ou transmis sur un réseau, tout en permettant au récepteur de retrouver exactement les frontières des chiffres initiaux lors de la lecture du flux binaire continu.

- Concaténation binaire : Assemblage séquentiel de mots binaires représentant chaque chiffre d'un nombre décimal.
- Alphabet décimal : Ensemble des M = 10 symboles fondamentaux (chiffres de 0 à 9) à encoder.
- Poids positionnel : Alignement strict de l'ordre d'origine des chiffres pour reconstruire la valeur numérique exacte.

Cas concret enseignant : *L'enseignant illustre le principe au tableau avec le nombre 123 : en décimal, c'est la juxtaposition des symboles '1', '2' et '3'. En binaire, si 1 a son propre code, 2 son code, et 3 son code, coller ces trois blocs bout à bout forme la représentation complète du nombre. La question posée à la classe est alors : combien de bits faut-il attribuer à chaque chiffre ?*

2. Analyse Mathématique Comparée : Format Fixe vs Format Variable Brut

Pour encoder M = 10 symboles distincts (les chiffres décimaux de 0 à 9) dans un alphabet binaire de cardinalité 2 : - **En Format Fixe** : Chaque symbole est représenté par un mot de même longueur N. Le nombre de combinaisons offertes par N bits est 2^N. Il faut déterminer le plus petit entier N respectant l'inéquation 2^N >= 10. Pour N = 3, 2^3 = 8 < 10 (insuffisant pour 10 chiffres). Pour N = 4, 2^4 = 16 >= 10 (valide). Le format fixe impose donc **N = 4 bits par chiffre**. - **En Format Variable Brut** : On s'autorise à utiliser des mots de 1 bit, de 2 bits, jusqu'à une longueur maximale N_max bits. La capacité totale de codage correspond à la somme des combinaisons de chaque niveau : 2^1 + 2^2 + ... + 2^N_max, ce qui équivaut à la somme géométrique 2^(N_max + 1) - 2. On cherche le plus petit N_max tel que 2^(N_max + 1) - 2 >= 10. Pour N_max = 2, 2^3 - 2 = 6 < 10. Pour N_max = 3, 2^4 - 2 = 14 >= 10 (valide). En format variable brut, la longueur maximale requise n'est que de **N_max = 3 bits**. Sur le plan théorique pur, le format variable est donc plus compact puisqu'il n'exige au maximum que 3 bits par chiffre contre 4

bits constants pour le format fixe.

- Format Fixe : Tous les mots binaires associés aux M symboles ont rigoureusement la même longueur N bits (Formule : 2^N >= M).
- Format Variable Brut : Les mots binaires ont des longueurs échelonnées de 1 à N_max bits (Formule : Sum(2^k pour k=1 à N_max) = 2^(N_max+1) - 2 >= M).
- Cardinalité de l'alphabet binaire : Taille de l'alphabet de codage |L| = 2 (les symboles 0 et 1).

Cas concret enseignant : *Le professeur écrit les deux formules au tableau et montre que pour N_max = 3 en format variable, on dispose de 2 mots de 1 bit (0, 1), 4 mots de 2 bits (00, 01, 10, 11) et 8 mots de 3 bits (000 à 111), soit un total de 2 + 4 + 8 = 14 combinaisons disponibles, ce qui suffit amplement pour caser nos 10 chiffres décimaux.*

3. Le Dilemme Compacité vs Décodabilité : L'Ambiguïté de Découpage (Framing)

Bien que le format variable brut paraisse supérieur en termes d'encombrement mémoire, il se heurte à un problème technique bloquant : la perte des frontières de mots (défaut de framing). En **Format Fixe (4 bits)**, le découpage à la réception est trivial et déterministe : sachant que chaque mot fait 4 bits, la machine réceptrice découpe le flux continu reçu par tranches strictes de 4 bits (bits 1 à 4 = 1er chiffre, bits 5 à 8 = 2ème chiffre, etc.) et reconstruit la valeur sans la moindre hésitation. En **Format Variable Brut**, en revanche, le flux binaire transmis ne contient aucun délimiteur d'espace. Si un mot peut faire 1, 2 ou 3 bits, plusieurs découpages deviennent théoriquement et pratiquement valides pour un même flux de bits. La machine réceptrice ne dispose d'aucun moyen logique pour savoir où s'arrête le premier chiffre et où commence le deuxième. Le code devient totalement ambigu et inutilisable.

- Framing / Découpage : Capacité du récepteur à identifier sans ambiguïté la fin d'un mot binaire et le début du suivant dans un flux continu.
- Ambiguïté de décodage : Perte d'unidicité de la séquence décodée due à l'absence de frontières claires entre les mots de longueurs variables.

Cas concret enseignant : *Le professeur utilise une métaphore marquante : lorsqu'on envoie le flux binaire codant 123 en format variable brut sans délimiteur, à la réception le processeur « est comme un couillon ». En effet, la séquence binaire reçue peut être découpée et lue comme étant le nombre 123, mais tout aussi bien comme le nombre 1212 ou encore 33 ! Sans règle de séparation, l'ordinateur est incapable de trancher.*

4. Levée d'Ambiguïté par Codes Auto-délimités et Calcul de Longueur Moyenne

Pour associer la compacité du format variable et la capacité de découpage déterministe du format fixe, on construit des **codes à longueur variable auto-délimités**. L'idée consiste à imposer une règle syntaxique de rupture dans la structure des bits. Exemple de règle proposée en cours : *« Dès que le motif binaire '10' est rencontré dans le flux, le mot binaire s'arrête impérativement au bit qui suit directement ce motif (avec une longueur maximale plafonnée à 5 bits) »*. En appliquant cette règle pour générer 10 mots binaires uniques attribués aux 10 chiffres décimaux (0 à 9), la somme totale des longueurs des 10 mots du dictionnaire atteint 38 bits. La longueur moyenne statistique par chiffre s'établit alors à : L_moyen = 38 / 10 = 3,8 bits par chiffre. **Bilan comparatif :** - Format Fixe = 4,0 bits/chiffre. - Format Variable Auto-délimité = 3,8 bits/chiffre. - Gain de compacité = (4,0 - 3,8) / 4,0 = 0,05 soit **5% d'économie** d'espace mémoire et de bande passante réseau, tout en garantissant un décodage 100% déterministe et instantané à la volée.

- Code auto-délimité (Code préfixe) : Code à longueur variable conçu pour que la fin de chaque mot soit détectée syntaxiquement sans séparateur externe.
- Règle de rupture / d'arrêt : Condition logique imposée sur la structure des bits (ex: arrêt immédiat au bit suivant le motif '10').
- Longueur moyenne (L_moyen) : Somme des longueurs de tous les mots du dictionnaire divisée par le nombre total de symboles (M = 10).

Cas concret enseignant : *L'enseignant fait calculer la somme des longueurs des 10 mots générés par la règle : 5 + 10 + 15... = 38 bits au total pour 10 symboles, soit 3,8 bits/chiffre en moyenne. Il conclut : « Même si nous sommes légèrement au-dessus des 3 bits théoriques du format variable brut, nous battons le format fixe de 4 bits avec 5% d'économie tout en sachant décoder parfaitement à la volée ! »*

■ Questions & Interventions des Étudiants en Classe

Question étudiant : Quel est l'avantage du format fixe si le format variable permet théoriquement d'avoir une longueur maximale plus courte (3 bits contre 4 bits) ?
Réponse du professeur : L'avantage absolu du format fixe est la simplicité et l'absence d'ambiguïté au découpage (framing). Comme chaque mot fait exactement 4 bits, la machine réceptrice découpe simplement le flux de 4 en 4 bits. Le format variable brut, bien que plus court (3 bits max), est inutilisable tel quel car le récepteur ne sait pas où couper et se retrouve 'comme un couillon' face à plusieurs interprétations possibles (ex: 123 vs 1212 vs 33).

Question étudiant : Dans la règle de délimitation proposée ('dès qu'on rencontre 10, on s'arrête au bit suivant'), comment s'applique l'arrêt pour le 3ème cas ou quand la longueur max de 5 bits est atteinte ?
Réponse du professeur : Dès que le motif 10 apparaît, la règle ordonne de lire exactement un bit supplémentaire puis de couper immédiatement le mot. Si le motif 10 n'apparaît pas mais qu'on atteint la longueur maximale autorisée (ici 5 bits), la structure du code impose également une coupure automatique. Cela garantit que chaque mot binaire est délimité de manière unique sans chevauchement.

■ Exercice & Démonstration d'Application

Énoncé : On souhaite encoder l'alphabet des M = 10 chiffres décimaux (0 à 9) pour les transmettre sous forme de flux binaire. 1. Calculer le nombre de bits minimal N requis en Format Fixe. 2. Calculer la longueur maximale N_max théorique en Format Variable Brut. 3. Soit un code variable auto-délimité dont les mots associés aux 10 chiffres ont pour longueurs respectives : [2, 3, 3, 4, 4, 4, 4, 4, 5, 5] bits. Calculer la longueur moyenne par chiffre (L_moyen) et le pourcentage de gain de stockage obtenu par rapport au format fixe.

Résolution pas à pas :
Étape 1 : Format Fixe On cherche le plus petit entier N tel que 2^N >= M (avec M = 10). - Pour N = 3 : 2^3 = 8 < 10 (insuffisant). - Pour N = 4 : 2^4 = 16 >= 10 (valide). Conclusion : N = 4 bits par chiffre. Étape 2 : Format Variable Brut On cherche le plus petit N_max tel que Sum(2^k pour k de 1 à N_max) = 2^(N_max + 1) - 2 >= 10. - Pour N_max = 2 : 2^(2+1) - 2 = 8 - 2 = 6 < 10 (insuffisant). - Pour N_max = 3 : 2^(3+1) - 2 = 16 - 2 = 14 >= 10 (valide). Conclusion : N_max = 3 bits. Étape 3 : Longueur Moyenne et Gain de Compacité - Somme des longueurs des 10 mots = 2 + 3 + 3 + 4 + 4 + 4 + 4 + 4 + 5 + 5 = 38 bits au total. - Longueur moyenne L_moyen = 38 / 10 = 3,8 bits par chiffre. - Gain de compacité relatif par rapport au format fixe (4 bits) : Gain = (N_fixe - L_moyen) / N_fixe = (4 - 3,8) / 4 = 0,2 / 4 = 0,05 soit 5%.

Résultat : Format fixe : 4 bits/chiffre | Format variable brut max : 3 bits | Format variable auto-délimité : 3,8 bits/chiffre en moyenne. Le code auto-délimité offre un gain de 5% de bande passante et de mémoire par rapport au format fixe, tout en éliminant 100% des ambiguïtés au décodage.

■ Auto-Évaluation Flash d'Examen

Q : Quelle est l'équation mathématique permettant de déterminer le nombre de bits N en format fixe pour encoder M symboles distincts ?

R : L'inéquation est 2^N >= M, où N est le nombre de bits (entier positif minimal) et M est le nombre de symboles à représenter (ex: M = 10 pour les chiffres décimaux, donnant N = 4 bits).

Q : Pourquoi la capacité totale d'un format variable de longueur maximale N_max s'exprime-t-elle par la formule 2^(N_max + 1) - 2 ?

R : Parce qu'elle additionne le nombre de combinaisons de toutes les longueurs de 1 à N_max bits : 2^1 + 2^2 + ... + 2^N_max. C'est la somme d'une suite géométrique de raison 2 dont le résultat est 2^(N_max + 1) - 2.

Q : Quel est le problème fondamental d'un codage en format variable brut et comment un code préfixe / auto-délimité le résout-il ?

> *R : Le problème fondamental est l'ambiguïté de découpage (loss of framing) : le récepteur ne sait pas où se termine un mot et où commence le suivant dans un flux continu. Un code auto-délimité le résout en imposant une règle syntaxique de rupture (ex: motif d'arrêt) permettant de détecter instantanément la fin d'un mot sans séparateur externe.*