Représentation et Codage Binaire des Chiffres Décimaux : Format Fixe, Format Variable et Levée d'Ambiguïté

Thème principal : Architecture des ordinateurs / Représentation des données - Codage des nombres et compromis compacité/décodabilité

Synthèse exécutive : Ce cours aborde la problématique fondamentale du codage binaire de grands nombres décimaux en décomposant chaque chiffre individuellement pour ensuite les concaténer (à l'image de la numération de position en base 10). L'enseignant compare rigoureusement deux approches fondamentales : le format fixe (où chaque symbole possède la même longueur N bits) et le format variable (où les mots ont des longueurs différentes). Si le format variable offre théoriquement une compacité supérieure (longueur maximale de 3 bits au lieu de 4 bits pour le format fixe), il introduit un risque majeur d'ambiguïté au décodage (perte des frontières de mots). Le cours démontre ensuite comment concevoir un code à longueur variable auto-délimité grâce à une règle syntaxique de rupture sur motif. Cette technique permet d'atteindre une longueur moyenne de 3,8 bits par chiffre (soit un gain de 5% de compacité par rapport au format fixe) tout en garantissant un décodage parfait, univoque et instantané.

1. Principe de Codage par Concaténation de Chiffres Décimaux

Pour représenter de grands nombres décimaux dans les systèmes informatiques, l'approche naturelle consiste à traiter chaque chiffre (de 0 à 9) de manière indépendante, à lui attribuer un code binaire spécifique, puis à concaténer (coller bout à bout) ces codes. Ce principe est l'exact équivalent de la numération de position en base 10 : le nombre '123' est formé par la succession du chiffre 1, puis du chiffre 2, puis du chiffre 3. Transposé en binaire, si le chiffre 1 possède un code binaire C(1), le chiffre 2 un code C(2), et le chiffre 3 un code C(3), le nombre 123 sera représenté par la séquence binaire concaténée C(1)C(2)C(3). L'enjeu central de cette démarche est de définir la longueur optimale de ces mots binaires afin de minimiser le volume de stockage et le débit réseau nécessaire, tout en permettant au système récepteur d'isoler sans ambiguïté chaque chiffre lors du décodage du flux continu de bits.

- Concaténation binaire : Assemblage séquentiel de mots binaires représentant chaque chiffre décimal d'un nombre.
- Alphabet décimal : Ensemble des 10 symboles fondamentaux à encoder (les chiffres de 0 à 9).
- Poids positionnel : Préservation stricte de l'ordre d'origine des chiffres pour reconstruire la valeur numérique exacte (ex: 123).

Cas concret enseignant : *L'enseignant illustre ce principe avec l'exemple concret du nombre 123 : en base 10, on assemble les symboles '1', '2' et '3'. En binaire, chaque chiffre reçoit son propre mot binaire ; en juxtaposant ces trois blocs, on obtient la représentation complète du nombre 123.*

2. Analyse Mathématique Comparée : Format Fixe vs Format Variable Brut

Pour coder M = 10 symboles distincts (les chiffres de 0 à 9) dans un alphabet binaire : - En Format Fixe : La capacité totale d'adressage avec N bits est 2^N. Il faut trouver le plus petit entier N tel que 2^N >= 10. Comme 2^3 = 8 < 10 et 2^4 = 16 >= 10, le format fixe impose obligatoirement N = 4 bits par chiffre. - En Format Variable : On cumule l'ensemble des combinaisons offertes par les mots de longueur 1 bit, de longueur 2 bits, jusqu'à N_max bits. Le nombre total de mots disponibles est la somme géométrique 2^1 + 2^2 + ... + 2^N_max = 2^(N_max + 1) - 2. On cherche le plus petit N_max tel que 2^(N_max + 1) - 2 >= 10. Pour N_max = 3, on obtient 2^4 - 2 = 14 >= 10. Ainsi, le format variable permet théoriquement d'utiliser une longueur maximale de seulement 3 bits.

- Format Fixe : Tous les mots binaires associés aux M symboles possèdent rigoureusement la même longueur N bits (Formule : 2^N >= M).
- Format Variable Brut : Les mots binaires ont des longueurs échelonnées de 1 bit jusqu'à une longueur maximale N_max bits (Formule de capacité : Somme géométrique 2^(N_max+1) - 2 >= M).
- Cardinalité de l'alphabet binaire : Taille de l'alphabet |L| = 2 (symboles 0 et 1).

Cas concret enseignant : *L'enseignant démontre au tableau que le format variable permet en théorie d'économiser de la longueur (max 3 bits au lieu de 4 bits fixes), car on exploite tous les mots de 1 bit (0, 1), de 2 bits (00, 01, 10, 11) et de 3 bits, ce qui génère 14 combinaisons, soit plus qu'il n'en faut pour nos 10 chiffres.*

3. Le Dilemme Compacité vs Décodabilité : L'Ambiguïté du Format Variable

La comparaison met en lumière un compromis fondamental en informatique. En Format Fixe (4 bits/chiffre), le découpage à la réception est trivial et déterministe : connaissant la règle, la machine découpe le flux par tranches de 4 bits (bits 1 à 4 = 1er chiffre, bits 5 à 8 = 2ème chiffre, etc.) et reconstruit immédiatement la valeur. À l'inverse, en Format Variable Brut, les mots ayant des longueurs de 1, 2 ou 3 bits, le récepteur perd la notion de frontière entre les symboles. À la réception d'une suite de bits, il devient techniquement impossible de savoir où se termine un chiffre et où commence le suivant. Le message est entaché d'ambiguïté majeure et s'avère inexploitable.

- Framing / Découpage : Capacité du processeur à identifier les frontières de chaque mot binaire dans un flux continu.
- Ambiguïté de décodage : Incertitude rendant un message binaire interprétable de multiples manières incompatibles (perte des frontières de mots).
- Avantage du format fixe : Simplicité absolue du découpage par blocs de taille constante.

Cas concret enseignant : *Le professeur utilise une métaphore marquante : si un processeur reçoit le flux binaire d'un format variable codant le nombre 123 sans délimiteur, la machine « est comme un couillon ». En effet, ce même flux binaire reçu peut être découpé et interprété tout aussi bien comme le nombre 123, que comme le nombre 1212 ou encore comme le nombre 33, car le système ne sait pas où placer les frontières.*

4. Levée d'Ambiguïté par Codes Auto-délimités et Longueur Moyenne

Pour marier la compacité du format variable et la simplicité de découpage du format fixe, on introduit une règle structurelle de délimitation. Par exemple : « Dès que le motif binaire '10' est rencontré, le mot s'arrête impérativement au bit immédiatement suivant (avec une longueur maximale tolérée de 5 bits) ». En appliquant cette règle pour construire les 10 mots binaires associés aux chiffres de 0 à 9, nous obtenons un dictionnaire dont la somme globale des longueurs s'élève à 38 bits pour les 10 symboles. La longueur moyenne statistique par chiffre s'établit à L_moyen = 38 / 10 = 3,8 bits par chiffre. Par rapport au format fixe (4,0 bits/chiffre), cela représente un gain de compacité de 5% tout en garantissant un décodage univoque et instantané.

- Code auto-délimité (Code préfixe) : Code à longueur variable conçu pour que la fin de chaque mot soit détectée sans séparateur externe, grâce à une règle syntaxique interne.
- Règle de rupture / d'arrêt : Condition logique imposée sur la structure des bits (ex: arrêt immédiat au bit suivant le motif '10').
- Longueur moyenne (L_moyen) : Moyenne pondérée des longueurs de l'ensemble des mots du dictionnaire de codage.

Cas concret enseignant : *L'enseignant fait effectuer le calcul aux étudiants : en additionnant les longueurs des 10 mots formés sous cette règle (5 + 10 + 15... = 38 bits au total), on obtient 3,8 bits en moyenne. Il conclut : « Même si nous sommes légèrement au-dessus du format variable brut (3 bits max), nous dépassons le format fixe de 4 bits avec 5% d'économie, tout en rendant le décodage parfait et instantané ! »*

■ Questions & Interventions des Étudiants en Classe

Question étudiant : Quel est l'intérêt de conserver le format fixe si le format variable permet d'avoir des mots binaires plus courts (3 bits max contre 4 bits fixe) ?
Réponse du professeur : Le format fixe garantit un découpage (framing) trivial et instantané du flux de données. Le format variable brut, bien que plus court en théorie, supprime les frontières entre les mots, ce qui rend le message totalement ambigu et illisible pour le récepteur.

Question étudiant : Pourquoi dans l'application de la règle de délimitation ('dès qu'on rencontre 10, on s'arrête au bit suivant'), le 3ème cas s'arrête-t-il à un endroit précis ?
Réponse du professeur : L'arrêt est dicté par la condition syntaxique de la règle de rupture combinée à la borne de sécurité maximale fixée à 5 bits pour éviter des mots infinis et garantir la couverture des 10 symboles décimaux.

■ Exercice & Démonstration d'Application

Énoncé : 1. Calculer le nombre de bits minimal N requis pour encoder les M = 10 chiffres décimaux (0 à 9) en Format Fixe. 2. Calculer la longueur maximale N_max requise en Format Variable brut. 3. Soit un code binaire auto-délimité attribuant aux 10 chiffres décimaux des mots de longueurs respectives [2, 3, 3, 4, 4, 4, 4, 4, 5, 5] bits. Calculer la longueur moyenne par chiffre et déterminer le pourcentage de gain de stockage obtenu par rapport au format fixe.

Résolution pas à pas :
1. Format Fixe : Condition : 2^N >= M avec M = 10. - Pour N = 3 : 2^3 = 8 (< 10) -> Insuffisant. - Pour N = 4 : 2^4 = 16 (>= 10) -> Valide. Conclusion : N = 4 bits par chiffre. 2. Format Variable Brut : Condition : Somme(2^k pour k de 1 à N_max) = 2^(N_max + 1) - 2 >= 10. - Pour N_max = 2 : 2^(2+1) - 2 = 8 - 2 = 6 (< 10) -> Insuffisant. - Pour N_max = 3 : 2^(3+1) - 2 = 16 - 2 = 14 (>= 10) -> Valide. Conclusion : N_max = 3 bits. 3. Longueur moyenne et Gain : - Somme des longueurs des 10 mots = 2 + 3 + 3 + 4 + 4 + 4 + 4 + 4 + 5 + 5 = 38 bits. - Longueur moyenne L_moyen = 38 / 10 = 3,8 bits par chiffre. - Calcul du gain relatif par rapport au format fixe (4 bits) : Gain = (N_fixe - L_moyen) / N_fixe = (4 - 3,8) / 4 = 0,2 / 4 = 0,05 = 5%.

Résultat : Format fixe : 4 bits/chiffre | Format variable brut max : 3 bits | Format variable auto-délimité : 3,8 bits/chiffre en moyenne. Le format auto-délimité apporte un gain de compacité de 5% par rapport au format fixe tout en éliminant 100% des ambiguïtés de décodage.

■ Auto-Évaluation Flash d'Examen

Q : Quelle est l'équation mathématique permettant de calculer le nombre de bits N en format fixe pour coder M symboles distincts ?

R : L'inéquation 2^N >= M (où N est le plus petit entier satisfaisant la condition).

Q : Pourquoi la capacité totale d'un format variable de longueur maximale N_max s'exprime-t-elle par la formule 2^(N_max + 1) - 2 ?

R : Parce qu'elle correspond à la somme géométrique du nombre de mots disponibles pour chaque longueur de 1 à N_max : Sum(2^k pour k de 1 à N_max) = 2^1 + 2^2 + ... + 2^N_max = 2^(N_max + 1) - 2.

Q : Quel est le problème fondamental du format variable brut lors du décodage d'un flux continu de bits et comment le résoudre ?

R : Le problème majeur est la perte des frontières de mots (ambiguïté de découpage ou 'loss of framing'). On le résout en concevant un code auto-délimité (code préfixe) intégrant une règle syntaxique de rupture.