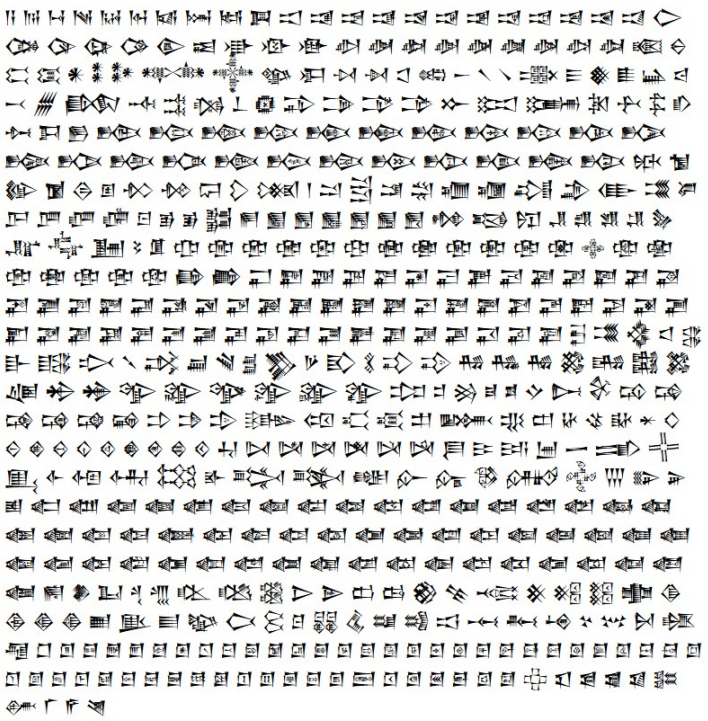


Unicode : cunéiforme

TD4

Codes UTF

Contrôle d'erreurs

Transmission

M1101 M. Dalmau IUT de Bayonne

Code UTF8 (codes sur 8 bits)

UTF8 (codes sur 1 octet)				b6	0	0	0	0	1	1	1	1
				b5	0	0	1	1	0	0	1	1
				b4	0	1	0	1	0	1	0	1
b3	b2	b1	b0									
0	0	0	0		NUL	DLE	SP	0	@	P	`	p
0	0	0	1		SOH	DC1	!	1	A	Q	a	q
0	0	1	0		STX	DC2	"	2	B	R	b	r
0	0	1	1		ETX	DC3	#	3	C	S	c	s
0	1	0	0		EOT	DC4	$	4	D	T	d	t
0	1	0	1		ENQ	NAK	%	5	E	U	e	u
0	1	1	0		ACK	SYN	&	6	F	V	f	v
0	1	1	1		BEL	ETB	'	7	G	W	g	w
1	0	0	0		BS	CAN	(	8	H	X	h	x
1	0	0	1		TAB	EM	)	9	I	Y	i	y
1	0	1	0		LF	SUB	*	:	J	Z	j	z
1	0	1	1		VT	ESC	+	;	K	[	k	{
1	1	0	0		FF	IS4	,	<	L	\	l	|
1	1	0	1		CR	IS3	-	=	M	]	m	}
1	1	1	0		SO	IS2	.	>	N	^	n	~
1	1	1	1		SI	IS1	/	?	O	_	o	DEL

Code UTF8 (codes sur 16 bits)

Les caractères accentués (ainsi que les signes de multiplication et de division) sont codés sur 2 octets dont le premier est 11000011 et le second (10xxxxxx) est donné par la table suivante :

2ème octet				b7	1	1	1	1
				b6	0	0	0	0
				b4	0	0	1	1
				b4	0	1	0	1
b3	b2	b1	b0					
0	0	0	0		À	Đ	à	ð
0	0	0	1		Á	Ñ	á	ñ
0	0	1	0		Â	Ò	â	ò
0	0	1	1		Ã	Ó	ã	ó
0	1	0	0		Ä	Ô	ä	ô
0	1	0	1		Å	Õ	å	õ
0	1	1	0		Æ	Ö	æ	ö
0	1	1	1		Ç	×	ç	÷
1	0	0	0		È	Ø	è	ø
1	0	0	1		É	Ù	é	ù
1	0	1	0		Ê	Ú	ê	ú
1	0	1	1		Ë	Û	ë	û
1	1	0	0		Ì	Ü	ì	ü
1	1	0	1		Í	Ý	í	ý
1	1	1	0		Î	Þ	î	þ
1	1	1	1		Ï	ß	ï	ÿ

Codage UTF8

On veut envoyer en UTF8 le mot "Bonjour"

1. Quels sont les codes à émettre ?

Recherche d'un code détecteur d'erreur

Comme il peut y avoir des erreurs de transmission, on décide d'envoyer les caractères en UTF8 mais en doublant chaque bit. Par exemple le caractère E dont le code UTF8 est 0100 0101 sera envoyé par : 00 11 00 00 00 11 00 11

Sur une transmission où on suppose qu'il ne peut pas y avoir plus d'une erreur par code envoyé, on reçoit :

00110000 11000011
00110111 00110011
00110011 00100000

1. Pour ceux qui n'ont pas d'erreur quel caractère représentent-ils ? Pour ceux qui ont une erreur quels caractères ça pouvait être ?

2. S'il pouvait y avoir 2 erreurs dans le même mot la détection d'erreur marcherait-elle ?

Code détecteur plus simple : la parité

Le principe est le suivant :

- On veut envoyer une information sur N bits
- On lui ajoute un bit (en général à gauche)
- La valeur de ce bit est choisie pour que le nombre total de bits à 1 dans l'information complète (N+1 bits) soit pair

Exemple :

- Pour envoyer 11010001 on enverra 011010001 (4 bits à 1)
- Pour envoyer 00010000 on enverra 100010000 (2 bits à 1)

Parité

1. On veut envoyer en UTF8 le mot "Bonjour" en ajoutant un bit de parité à gauche à chaque code UTF8. Quels sont les codes envoyés ?

2. S’il pouvait y avoir 2 erreurs dans le même code UTF8 la détection d’erreur marcherait-elle ?

On veut envoyer un texte de 1000 caractères en UTF8 dans lequel :

- 902 caractères sont codés sur 8 bits
- 88 caractères sont codés sur 16 bits
- 8 caractères sont codés sur 24 bits
- 2 caractères sont codés sur 32 bits

1. Quel est le nombre de bits envoyés si on utilise la méthode vue précédemment qui envoie chaque bit en double et si on utilise la méthode de la parité ?

Meilleure solution ?

On décide d'envoyer les caractères en UTF8 mais en triplant chaque bit

Sur une transmission où on suppose qu'il ne peut pas y avoir plus d'une erreur par code envoyé, on reçoit :

- 000111111010 000000111000
- 000111111000 111111111111
- 000000111111 000000110000

1. Lesquels sont justes et les quels sont faux ?
2. Corriger les erreurs quels sont les caractères envoyés ?
3. S'il pouvait y avoir 2 erreurs dans le même mot pourrait-on corriger l'erreur ? Pourrait-on au moins la détecter ?

Parité bidimensionnelle

Principe :

- La parité permet de détecter une erreur sur un groupe de N bits
- Mais on ne sait pas lequel des N bits est faux
- Si l'on envoie K groupes de N bits avec un bit de parité sur chacun et que l'on suppose qu'il n'y ait pas plus d'une erreur sur tout l'envoi. En cas d'erreur, la parité permet de savoir lequel des K groupes est faux mais pas lequel des N bits de ce groupe est faux

Exemple pour K=3 et N = 8 :

1 00011001
1 00100001
1 01111001

On sait que le 2ème code est faux

Parité bidimensionnelle

L'idée :

- On ajoute à la fin des K codes avec parité un code supplémentaire qui contient les bits de parité verticale

Exemple pour K=3 et N = 8 :

1 00011001
1 00101001
1 01111001
1 01001001

On sait que le 2ème code est faux

Mais on sait aussi que le 6ème bit est faux

Donc on peut corriger le 6ème bit du 2ème code

Correction d'erreurs

On a reçu en UTF8 contrôlé par parité bidimensionnelle (bit de gauche + mot de parité chaque 6 octets) les codes suivants :

1 0100 1001
1 0110 1110
0 0110 0110
0 0111 1111
0 0111 0010
1 0110 1101
1 0011 0001
1 0110 0001
0 0111 0100
0 0110 1001
0 0111 0001
0 0111 0101
0 0110 0101
0 0001 1101

1. Après avoir corrigé les éventuelles erreurs, trouver le message reçu.

2. S'il pouvait y avoir 2 erreurs dans le même bloc (6 octets + 1 octet de contrôle) pourrait-on corriger l'erreur ? Pourrait-on au moins la détecter ?

Evaluation

On veut envoyer le même texte de 1000 caractères en UTF8 dans lequel :

- 902 caractères sont codés sur 8 bits
- 88 caractères sont codés sur 16 bits
- 8 caractères sont codés sur 24 bits
- 2 caractères sont codés sur 32 bits

1. Quel est le nombre de bits envoyés si on utilise la méthode vue précédemment qui envoie chaque bit en triple exemplaire et si on utilise la méthode de la parité bidimensionnelle en mettant un contrôle chaque 6 octets ?

Compléments

La parité bidimensionnelle suppose l'envoi d'un code supplémentaire chaque K codes envoyés. Pour qu'elle fonctionne il faut qu'il n'y ait pas plus d'une erreur sur un bloc complet

Si on envoie des informations sur N bits et que l'on constitue des blocs de K informations, chaque bloc contient (K+1)*(N+1) bits. Il faut qu'il n'y ait pas plus d'une erreur sur ces (K+1)*(N+1) bits.

Hypothèse de qualité :

- Lorsque l'on transmet par un réseau on connaît le taux moyen d'erreurs de ce réseau. Ce taux peut permettre de calculer K.

Exemple : si un réseau a un taux d'erreur de 1 sur 1 million et que l'on envoie des informations sur 8 bits on trouve que (K+1)*9 doit être inférieur à 1 million $\Rightarrow$ K < 111 110

Pour être prudents on peut ajouter un code de contrôle tous le 10 000 octets

Transmission de textes

On transmet un texte ligne par ligne selon les règles suivantes :

- Chaque caractère est codé en UTF8 avec un bit de parité paire à gauche
- Chaque ligne débute par le caractère STX et se termine par un code de parité verticale
- Le texte est terminé par le caractère EOT

1. Quels sont les codes émis pour transmettre le texte de 2 lignes suivant :

   1997

   Année

2. En quoi ce texte présente-t-il un problème pour le récepteur ?

Exemple de texte émis :

STX
C1
C2
.
.
.
Cn
Parité verticale
STX
.
.
.
Parité verticale
STX
.
.
.
parité verticale
EOT

Mauvaise interprétation

1. Quelle solution proposer à ce problème de mauvaise interprétation ?