Codage Binaire des Chiffres Décimaux : Format Fixe, Format Variable et Levée d'Ambiguïté par Codes Auto-délimités

Thème principal : Représentation binaire des symboles décimaux, calcul de capacité binaire, framing et levée d'ambiguïté de découpage

Synthèse exécutive : Pour représenter de grands nombres décimaux en informatique, une approche naturelle consiste à coder chaque chiffre décimal (de 0 à 9) séparément sous forme d'un mot binaire, puis à les concaténer. Ce cours examine la confrontation fondamentale entre le Format Fixe (4 bits par chiffre, découpage trivial mais gourmand en mémoire) et le Format Variable Brut (3 bits max, très compact mais indécodable par manque de frontières de mots). Pour résoudre ce dilemme, le cours introduit les codes à longueur variable auto-délimités, fondés sur des règles de rupture syntaxique. Ces codes permettent d'obtenir un décodage univoque et instantané avec une longueur moyenne de 3,8 bits par chiffre, réalisant un gain de 5% de bande passante et de stockage par rapport au format fixe.

Principe de Codage par Concaténation des Chiffres Décimaux

Pour représenter de grands nombres décimaux dans une architecture informatique, une approche directe consiste à traiter chaque chiffre décimal (de 0 à 9) indépendamment, à lui associer un code binaire spécifique, puis à concaténer (coller bout à bout) ces mots binaires. Ce principe est l'exact équivalent de notre numération de position en base 10 : le nombre '123' est formé par la juxtaposition du chiffre 1, puis du chiffre 2, puis du chiffre 3. Transposé en binaire, si le chiffre 1 possède un code binaire C(1), le chiffre 2 un code C(2), et le chiffre 3 un code C(3), le nombre 123 sera représenté par la séquence binaire concaténée C(1)C(2)C(3). L'enjeu central de ce cours réside dans la détermination de la longueur optimale des mots binaires attribués à chaque chiffre afin de minimiser le volume de stockage et le débit réseau nécessaire, tout en garantissant un décodage exact au récepteur.

- Concaténation binaire : Juxtaposition séquentielle des mots binaires codant chaque chiffre décimal individuel.
- Alphabet décimal : Ensemble des M = 10 symboles de base (de 0 à 9) à représenter.
- Poids positionnel : Alignement strict de l'ordre des mots binaires pour reconstruire la valeur numérique exacte.

Cas concret enseignant : *L'enseignant illustre ce principe avec le nombre 123 : en base 10, on assemble les symboles '1', '2' et '3'. En binaire, chaque chiffre reçoit son propre mot binaire ; en juxtaposant ces trois blocs, on obtient la représentation complète du nombre 123.*

Analyse Mathématique Comparée : Format Fixe vs Format Variable Brut

Pour encoder M = 10 symboles distincts (les chiffres de 0 à 9) avec un alphabet binaire : - En Format Fixe : La capacité totale d'adressage avec N bits est 2^N. Nous cherchons le plus petit entier N tel que 2^N >= 10. Pour N = 3, 2^3 = 8 < 10 (insuffisant). Pour N = 4, 2^4 = 16 >= 10 (valide). Le format fixe impose donc obligatoirement N = 4 bits par chiffre. - En Format Variable Brut : On cumule l'ensemble des combinaisons offertes par les mots de longueur 1 bit, de longueur 2 bits, jusqu'à N_max bits. Le nombre total de mots disponibles est la somme géométrique 2^1 + 2^2 + ... + 2^N_max = 2^(N_max + 1) - 2. Nous cherchons le plus petit N_max tel que 2^(N_max + 1) - 2 >= 10. Pour N_max = 2, 2^3 - 2 = 6 < 10. Pour N_max = 3, 2^4 - 2 = 14 >= 10 (valide). En format variable brut, la longueur maximale n'est que de N_max = 3 bits, ce qui prouve qu'en théorie pure, le format variable est plus compact.

- Format Fixe : Tous les mots binaires associés aux M symboles ont la même longueur N bits (Equation : 2^N >= M).
- Format Variable Brut : Les mots binaires ont des longueurs échelonnées de 1 à N_max bits (Equation : 2^(N_max+1) - 2 >= M).
- Cardinalité de l'alphabet binaire : Taille de l'alphabet binaire |L| = 2 (symboles 0 et 1).

Cas concret enseignant : *Le professeur démontre la formule au tableau : avec N_max = 3, on dispose de 2 mots de 1 bit (0, 1), 4 mots de 2 bits (00, 01, 10, 11) et 8 mots de 3 bits (000 à 111), ce qui génère 2 + 4 + 8 = 14 combinaisons. C'est plus que suffisant pour nos 10 chiffres décimaux !*

Le Problème de l'Ambiguïté et la Notion de Framing (Découpage)

La comparaison entre les deux formats met en lumière un compromis fondamental en informatique : - En Format Fixe (4 bits/chiffre), le découpage à la réception est trivial et déterministe : sachant que chaque chiffre occupe 4 bits, la machine découpe le flux continu reçu par tranches de 4 bits (bits 1 à 4 = 1er chiffre, bits 5 à 8 = 2ème chiffre, etc.) et reconstruit immédiatement la valeur d'origine. - En Format Variable Brut, en revanche, les mots ayant des longueurs de 1, 2 ou 3 bits, le récepteur perd la notion de frontière entre les symboles. À la réception d'une suite de bits, il devient techniquement impossible de savoir où se termine un chiffre et où commence le suivant. Le message est entaché d'une ambiguïté majeure et s'avère inexploitable.

- Framing / Découpage : Capacité du processeur à identifier sans ambiguïté les limites de chaque mot binaire dans un flux continu.
- Ambiguïté de décodage : Incertitude rendant un message binaire interprétable de multiples manières incompatibles.
- Inconvénient du Format Variable Brut : Perte de la frontière des mots due à l'absence de longueur fixe ou de délimiteurs.

Cas concret enseignant : *Le professeur utilise une métaphore marquante : si un processeur reçoit le flux binaire d'un format variable codant le nombre 123 sans délimiteur, la machine « est comme un couillon ». En effet, ce même flux binaire reçu peut être découpé et interprété tout aussi bien comme le nombre 123, que comme le nombre 1212 ou encore comme le nombre 33, car le système ne sait pas où placer les frontières.*

Levée d'Ambiguïté par Codes Auto-délimités et Calcul de la Longueur Moyenne

Pour marier la compacité du format variable et la simplicité de découpage du format fixe, on introduit une règle structurelle de délimitation. Exemple de règle : 'Dès que le motif binaire 10 est rencontré, le mot s'arrête impérativement au bit immédiatement suivant (avec une longueur maximale tolérée de 5 bits)'. En appliquant cette règle pour construire les 10 mots binaires associés aux chiffres de 0 à 9, nous obtenons un dictionnaire dont la somme globale des longueurs s'élève à 38 bits pour les 10 symboles. La longueur moyenne statistique par chiffre s'établit à : L_moyen = 38 / 10 = 3,8 bits par chiffre. Par rapport au format fixe (4,0 bits/chiffre), cela représente un gain de compacité de (4,0 - 3,8) / 4,0 = 5% d'économie d'espace mémoire et de bande passante, tout en conservant une garantie totale de décodage non ambigu à la volée.

- Code auto-délimité (Code préfixe) : Code à longueur variable conçu pour que la fin de chaque mot soit détectée sans séparateur externe.
- Règle de rupture / d'arrêt : Condition syntaxique imposée sur la structure des bits (ex: arrêt immédiat au bit suivant le motif '10').
- Longueur moyenne (L_moyen) : Somme des longueurs de tous les mots du dictionnaire divisée par le nombre total de symboles.

Cas concret enseignant : *L'enseignant fait effectuer le calcul aux étudiants : en additionnant les longueurs des 10 mots formés sous cette règle (somme = 38 bits au total pour 10 chiffres), on obtient 3,8 bits en moyenne. Il conclut : « Même si nous sommes légèrement au-dessus du format variable brut (3 bits max), nous dépassons le format fixe de 4 bits avec 5% d'économie, tout en rendant le décodage parfait et instantané ! »*

■ Questions & Interventions des Étudiants en Classe

Question étudiant : Pourquoi le format variable brut pose-t-il un problème de décodage si ses mots binaires sont plus courts (3 bits max contre 4 bits fixe) ?
Réponse du professeur : Parce qu'en format variable brut, les mots n'ont pas tous la même taille (1, 2 ou 3 bits). Quand le récepteur reçoit une suite continue de 0 et de 1, il ne sait pas où un mot s'arrête et où le suivant commence, ce qui crée une ambiguïté (ex: le même flux binaire peut être interprété comme 123, 1212 ou 33).

Question étudiant : Comment fonctionne exactement la règle de délimitation proposée en cours ('dès qu'on rencontre 10, on s'arrête au bit suivant') pour éviter cette ambiguïté ?
Réponse du professeur : La règle impose une contrainte syntaxique sur la structure des bits : dès que la séquence '10' apparaît, le décodeur sait de manière autonome que le mot se termine juste après le bit suivant. Cela permet au récepteur de repérer les frontières de chaque chiffre à la volée, sans séparateur explicite.

■ Exercice & Démonstration d'Application

Énoncé : 1. Calculer le nombre de bits minimal N requis pour encoder les M = 10 chiffres décimaux (0 à 9) en Format Fixe. 2. Calculer la longueur maximale N_max requise en Format Variable brut. 3. Soit un code binaire auto-délimité attribuant aux 10 chiffres décimaux des mots de longueurs respectives [2, 3, 3, 4, 4, 4, 4, 4, 5, 5] bits. Calculer la longueur moyenne par chiffre et déterminer le pourcentage de gain de stockage obtenu par rapport au format fixe.

Résolution pas à pas :
1. Format Fixe : Condition : 2^N >= M avec M = 10. - Pour N = 3 : 2^3 = 8 (< 10) -> Insuffisant. - Pour N = 4 : 2^4 = 16 (>= 10) -> Valide. Conclusion : N = 4 bits par chiffre. 2. Format Variable Brut : Condition : Sum(2^k pour k de 1 à N_max) = 2^(N_max + 1) - 2 >= 10. - Pour N_max = 2 : 2^(2+1) - 2 = 8 - 2 = 6 (< 10) -> Insuffisant. - Pour N_max = 3 : 2^(3+1) - 2 = 16 - 2 = 14 (>= 10) -> Valide. Conclusion : N_max = 3 bits. 3. Longueur moyenne et Gain : - Somme des longueurs des 10 mots = 2 + 3 + 3 + 4 + 4 + 4 + 4 + 4 + 5 + 5 = 38 bits. - Longueur moyenne L_moyen = 38 / 10 = 3,8 bits par chiffre. - Calcul du gain relatif par rapport au format fixe (4 bits) : Gain = (N_fixe - L_moyen) / N_fixe = (4 - 3,8) / 4 = 0,2 / 4 = 0,05 = 5%.

Résultat : Format fixe : 4 bits/chiffre | Format variable brut max : 3 bits | Format variable auto-délimité : 3,8 bits/chiffre en moyenne. Le format auto-délimité apporte un gain de compacité de 5% par rapport au format fixe tout en éliminant 100% des ambiguïtés de décodage.

■ Auto-Évaluation Flash d'Examen

Q : Quelle est la condition mathématique permettant d'établir le nombre de bits N en format fixe pour coder M symboles distincts ?

R : La condition est 2^N >= M, où N est le plus petit entier satisfaisant l'inéquation. Pour M = 10 symboles décimaux, 2^4 = 16 >= 10, soit N = 4 bits par chiffre.

Q : Pourquoi la formule de capacité totale d'un format variable de longueur maximale N_max s'écrit-elle 2^(N_max + 1) - 2 ?

R : Parce qu'elle représente la somme géométrique du nombre de mots de 1 bit (2^1), de 2 bits (2^2), jusqu'à N_max bits (2^N_max). La somme de cette suite vaut 2^(N_max + 1) - 2.

Q : Quel est le problème fondamental du format variable brut lors du décodage d'un flux continu de bits et comment le résoudre ?

R : Le problème est l'ambiguïté de découpage (perte de framing) : le récepteur ne peut pas savoir où s'arrête un mot et où commence le suivant. On le résout en utilisant un code auto-délimité avec une règle de rupture syntaxique sur les mots.

Fiche académique générée et vérifiée par Kai pour Matéi • Hébergée sur http://88.96.47.180:8765