Représentation et Codage Binaire des Chiffres Décimaux : Format Fixe, Format Variable et Levée d'Ambiguïté par Codes Auto-délimités

Thème principal : Architecture et Codage de l'Information — Formats Fixe et Variable, Framing et Codes Auto-délimités

Synthèse exécutive : Ce cours aborde la problématique fondamentale du codage binaire de grands nombres décimaux en encodant séparément chaque chiffre de l'alphabet décimal (0 à 9) avant de les concaténer, à l'image de la numération de position en base 10. Il compare de manière rigoureuse le Format Fixe (où chaque chiffre occupe le même nombre N de bits) et le Format Variable Brut (où la longueur des mots s'échelonne jusqu'à N_max). L'analyse mathématique démontre qu'en format fixe, l'inéquation 2^N >= 10 impose N = 4 bits par chiffre, tandis qu'en format variable brut, la somme géométrique 2^(N_max+1) - 2 >= 10 autorise une longueur maximale N_max = 3 bits. Cependant, le format variable brut détruit les frontières de mots binaires (perte du framing), rendant le message totalement ambigu à la réception (« la machine réceptrice est comme un couillon »). Pour surmonter ce blocage tout en conservant une grande compacité, le cours présente la conception d'un code à longueur variable auto-délimité basé sur une règle syntaxique de rupture (ex: arrêt dès la rencontre du motif '10'). Ce système atteint une longueur moyenne de 3,8 bits par chiffre (gain de 5% de bande passante et mémoire par rapport au format fixe) tout en garantissant un décodage parfait, univoque et instantané.

1. Principe de Codage par Concaténation de Chiffres Décimaux

Pour représenter de grands nombres décimaux au sein d'une architecture informatique, l'approche retenue consiste à encoder chaque chiffre de l'alphabet décimal (de 0 à 9) sous la forme d'un mot binaire indépendant, puis à juxtaposer (concaténer) ces mots binaires pour former le nombre final. Ce fonctionnement reflète exactement la numération positionnelle en base 10 : écrire le nombre '123' revient à juxtaposer le symbole '1', le symbole '2', puis le symbole '3'. Transposé en binaire, si le chiffre 1 possède un mot binaire attribué C(1), le chiffre 2 un mot C(2), et le 3 un mot C(3), le nombre 123 sera représenté par le bloc binaire continu C(1)C(2)C(3). L'enjeu central réside dans le choix de la longueur de ces mots binaires : il s'agit de minimiser l'empreinte mémoire et le volume de données transmises sur un réseau tout en garantissant au processeur récepteur la capacité de séparer correctement les chiffres lors de la lecture du flux continu de bits.

- Concaténation binaire : Assemblage séquentiel de mots binaires représentant chaque chiffre individuel d'un nombre décimal.
- Alphabet décimal : Ensemble des M = 10 symboles fondamentaux à encoder (les chiffres de 0 à 9).
- Poids positionnel : Conservation stricte de l'ordre d'origine des chiffres pour reconstruire la valeur numérique exacte.

Cas concret enseignant : *Le professeur illustre le principe au tableau avec le nombre 123 : en décimal, on associe le chiffre 1, puis le 2, puis le 3 pour former 123. En binaire, si le 1 a un code binaire donné, le 2 son code, et le 3 son code, la concaténation de ces trois blocs constitue la représentation complète du nombre. La question fondamentale posée à la classe est alors : quelle doit être la longueur des mots binaires attribués à chaque chiffre ?*

2. Analyse Mathématique Comparée : Format Fixe vs Format Variable Brut

Pour encoder M = 10 symboles distincts (les chiffres décimaux de 0 à 9) dans un alphabet binaire de taille 2 ({0, 1}) : 1. **En Format Fixe** : La capacité totale d'adressage offerte par des mots de N bits est 2^N. Il faut déterminer le plus petit entier N respectant l'inéquation 2^N >= 10. Pour N = 3, 2^3 = 8 < 10 (insuffisant pour 10 symboles). Pour N = 4, 2^4 = 16 >= 10 (valide). Le format fixe impose donc obligatoirement **N = 4 bits par chiffre**. 2. **En Format Variable Brut** : On cumule les combinaisons offertes par les mots de 1 bit, de 2 bits, jusqu'à une longueur maximale N_max bits. La capacité totale correspond à la somme d'une suite géométrique : 2^1 + 2^2 + ... + 2^N_max = 2^(N_max + 1) - 2. On cherche le plus petit N_max tel que 2^(N_max + 1) - 2 >= 10. Pour N_max = 2,

2^3 - 2 = 6 < 10. Pour N_max = 3, 2^4 - 2 = 14 >= 10 (valide). En format variable brut, la longueur maximale requise n'est donc que de **N_max = 3 bits**. Sur le plan théorique pur, le format variable paraît plus compact puisqu'il ne nécessite au maximum que 3 bits par chiffre là où le format fixe en exige 4 systématiquement.

- Format Fixe : Tous les mots binaires associés aux M symboles ont rigoureusement la même longueur N bits (Équation : 2^N >= M).
- Format Variable Brut : Les mots binaires ont des longueurs échelonnées de 1 à N_max bits (Équation : Sum(2^k pour k=1 à N_max) = 2^(N_max+1) - 2 >= M).
- Cardinalité de l'alphabet binaire : Taille de l'alphabet de codage |L| = 2 (symboles 0 et 1).

Cas concret enseignant : *Le professeur écrit les deux formules au tableau et montre que pour N_max = 3 en format variable, on dispose de 2 mots de 1 bit (0, 1), 4 mots de 2 bits (00, 01, 10, 11) et 8 mots de 3 bits (000 à 111), ce qui génère 2 + 4 + 8 = 14 combinaisons disponibles, soit plus qu'il n'en faut pour nos 10 chiffres décimaux.*

3. Le Dilemme Compacité vs Décodabilité : L'Ambiguïté du Format Variable (Framing)

La comparaison entre les deux formats met en lumière un compromis fondamental en informatique entre compacité et facilité de traitement : - **En Format Fixe (4 bits)**, le découpage à la réception est déterministe et immédiat : sachant que chaque mot fait 4 bits, la machine réceptrice découpe le flux continu reçu par tranches strictes de 4 bits (bits 1 à 4 = 1er chiffre, bits 5 à 8 = 2ème chiffre, etc.) et reconstruit la valeur sans la moindre hésitation. - **En Format Variable Brut**, en revanche, le flux binaire transmis ne comporte aucun délimiteur d'espace. Si un mot peut mesurer 1, 2 ou 3 bits, plusieurs découpages deviennent théoriquement et pratiquement valides pour un même flux de bits. Le récepteur n'a aucun moyen logique d'identifier où s'arrête le premier chiffre et où commence le suivant. Le message est entaché d'une ambiguïté bloquante qui le rend inutilisable.

- Framing / Découpage : Capacité du récepteur à identifier sans ambiguïté la fin d'un mot binaire et le début du suivant dans un flux continu.
- Ambiguïté de décodage : Incertitude rendant un message binaire interprétable de multiples manières incompatibles.
- Avantage du Format Fixe : Découpage déterministe et trivial par blocs de taille constante.

Cas concret enseignant : *Le professeur utilise une métaphore marquante : lorsqu'on envoie le flux binaire codant 123 en format variable brut sans délimiteur, à la réception le processeur « est comme un couillon ». En effet, la séquence binaire reçue peut être découpée et lue comme étant le nombre 123, mais tout aussi bien comme le nombre 1212 ou encore 33 ! Sans règle de séparation, l'ordinateur est incapable de trancher.*

4. Levée d'Ambiguïté par Codes Auto-délimités et Calcul de Longueur Moyenne

Pour concilier la compacité du format variable et le décodage sans ambiguïté du format fixe, on construit des **codes à longueur variable auto-délimités**. L'idée consiste à imposer une règle syntaxique de rupture dans la structure même des bits. Exemple de règle analysée en cours : *« Dès que le motif binaire '10' est rencontré dans le flux, le mot binaire s'arrête impérativement au bit qui suit directement ce motif (avec une longueur maximale plafonnée à 5 bits) »*. En appliquant cette règle pour générer 10 mots binaires uniques attribués aux 10 chiffres décimaux (0 à 9), la somme totale des longueurs des 10 mots du dictionnaire s'élève à 38 bits. La longueur moyenne statistique par chiffre s'établit alors à : L_moyen = 38 / 10 = 3,8 bits par chiffre. **Bilan comparatif :** - Format Fixe = 4,0 bits/chiffre. - Format Variable Auto-délimité = 3,8 bits/chiffre. - Gain de compacité = (4,0 - 3,8) / 4,0 = 0,05 soit **5% d'économie** d'espace mémoire et de bande passante réseau, tout en garantissant un décodage 100% déterministe et instantané à la volée.

- Code auto-délimité (Code préfixe) : Code à longueur variable conçu de telle sorte que la fin de chaque mot est détectée de façon univoque sans séparateur externe.
- Règle de rupture / d'arrêt : Condition syntaxique imposée sur la structure des bits (ex: arrêt immédiat au bit suivant le motif '10').
- Longueur moyenne (L_moyen) : Somme des longueurs de tous les mots du dictionnaire divisée par le nombre total de symboles (M = 10).

Cas concret enseignant : *L'enseignant fait effectuer le calcul de la somme des longueurs des 10 mots générés par la règle : 5 + 10 + 15... = 38 bits au total pour 10 symboles, soit 3,8 bits/chiffre en moyenne. Il conclut : « Même si nous sommes légèrement au-dessus des 3 bits théoriques du format variable brut, nous battons le format fixe de 4 bits avec 5% d'économie tout en sachant décoder parfaitement à la volée ! »*

■ Questions & Interventions des Étudiants en Classe

Question étudiant : Quel est l'avantage du format fixe si le format variable permet théoriquement d'avoir une longueur maximale plus courte (3 bits contre 4 bits) ?
Réponse du professeur : Le format fixe garantit la simplicité absolue du découpage (framing). Comme chaque mot fait exactement 4 bits, la machine réceptrice découpe le flux de 4 en 4 bits sans aucune ambiguïté. Le format variable brut, quant à lui, crée un chevauchement indécodable à la réception car la machine ne sait pas où s'arrêtent les mots.

Question étudiant : Dans la règle de délimitation proposée ('dès qu'on rencontre 10, on s'arrête au bit suivant'), comment s'applique l'arrêt pour le 3ème cas ou quand la longueur max de 5 bits est atteinte ?
Réponse du professeur : La règle s'applique strictement dès la première occurrence du motif '10' : le récepteur lit 1 bit supplémentaire et stoppe le mot. Si le motif n'est pas rencontré avant la limite fixée (5 bits), la longueur maximale agit comme un garde-fou automatique pour stopper la lecture. Cela garantit une construction finie et délimitée de chaque mot du dictionnaire.

■ Exercice & Démonstration d'Application

Énoncé : On souhaite encoder l'alphabet des M = 10 chiffres décimaux (0 à 9) pour les transmettre sous forme de flux binaire. 1. Calculer le nombre de bits minimal N requis en Format Fixe. 2. Calculer la longueur maximale N_max théorique en Format Variable Brut. 3. Soit un code variable auto-délimité dont les mots associés aux 10 chiffres ont pour longueurs respectives : [2, 3, 3, 4, 4, 4, 4, 4, 5, 5] bits. Calculer la longueur moyenne par chiffre (L_moyen) et le pourcentage de gain de stockage obtenu par rapport au format fixe.

Résolution pas à pas :
Étape 1 : Format Fixe On cherche le plus petit entier N tel que 2^N >= M (avec M = 10). - Pour N = 3 : 2^3 = 8 < 10 (insuffisant). - Pour N = 4 : 2^4 = 16 >= 10 (valide). Conclusion : N = 4 bits par chiffre. Étape 2 : Format Variable Brut On cherche le plus petit N_max tel que Sum(2^k pour k de 1 à N_max) = 2^(N_max + 1) - 2 >= 10. - Pour N_max = 2 : 2^(2+1) - 2 = 8 - 2 = 6 < 10 (insuffisant). - Pour N_max = 3 : 2^(3+1) - 2 = 16 - 2 = 14 >= 10 (valide). Conclusion : N_max = 3 bits. Étape 3 : Longueur Moyenne et Gain de Compacité - Somme des longueurs des 10 mots = 2 + 3 + 3 + 4 + 4 + 4 + 4 + 4 + 5 + 5 = 38 bits au total. - Longueur moyenne L_moyen = 38 / 10 = 3,8 bits par chiffre. - Gain de compacité relatif par rapport au format fixe (4 bits) : Gain = (N_fixe - L_moyen) / N_fixe = (4 - 3,8) / 4 = 0,2 / 4 = 0,05 soit 5%.

Résultat : Format fixe : 4 bits/chiffre | Format variable brut max : 3 bits | Format variable auto-délimité : 3,8 bits/chiffre en moyenne. Le code auto-délimité offre un gain de 5% de bande passante et de mémoire par rapport au format fixe, tout en éliminant 100% des ambiguïtés au décodage.

■ Auto-Évaluation Flash d'Examen

Q : Quelle est l'équation mathématique permettant de déterminer le nombre de bits N en format fixe pour encoder M symboles distincts ?

R : L'inéquation est 2^N >= M, où N est le nombre entier de bits minimal recherché.

Q : Pourquoi la capacité totale d'un format variable de longueur maximale N_max s'exprime-t-elle par la formule 2^(N_max + 1) - 2 ?

R : Parce qu'elle correspond à la somme des combinaisons de mots de 1 bit (2^1), 2 bits (2^2) jusqu'à N_max bits (2^N_max). Il s'agit d'une somme géométrique dont la formule simplifiée est 2^(N_max + 1) - 2.

Q : Quel est le problème fondamental d'un codage en format variable brut et comment un code préfixe / auto-délimité le résout-il ?

R : Le format variable brut supprime les frontières entre les mots (perte de framing), rendant le flux binaire ambigu et indécodable à la réception. Un code auto-délimité résout ce problème en introduisant une règle syntaxique de rupture (arrêt sur motif) qui permet au récepteur de détecter la fin de chaque mot à la volée.