Représentation et Codage Binaire des Chiffres Décimaux : Format Fixe, Format Variable Brut et Codes Auto-délimités

Thème principal : Codage Binaire des Chiffres Décimaux, Théorie de la Capacité, Ambiguïté de Décodage et Levée d'Ambiguïté par Règles de Rupture

Synthèse exécutive : Ce cours aborde la problématique fondamentale du codage binaire des nombres décimaux en décomposant chaque chiffre (de 0 à 9) pour les juxtaposer (concaténation), sur le principe de la numération de position. Deux approches fondamentales sont analysées et comparées : le Format Fixe (où tous les mots ont la même longueur N bits) et le Format Variable Brut (où la longueur des mots s'échelonne jusqu'à N_max bits). Sur le plan théorique, le format fixe impose 4 bits par chiffre (via 2^N >= 10), alors que le format variable permet d'avoir des mots d'une longueur maximale de 3 bits seulement (via 2^(N_max+1) - 2 >= 10). Toutefois, le format variable brut supprime les frontières entre mots binaires et rend le flux totalement ambigu et indécodable à la réception. Pour concilier la compacité du format variable et le découpage déterministe du format fixe, le cours démontre la création de codes à longueur variable auto-délimités (codes préfixes) basés sur des règles syntaxiques de rupture sur motif. Ce système atteint une longueur moyenne de 3,8 bits par chiffre (gain de 5% par rapport au format fixe) tout en garantissant un décodage exact et univoque à la volée.

1. Principe de Codage par Concaténation de Chiffres Décimaux

Pour représenter de grands nombres décimaux dans les systèmes informatiques, une approche naturelle consiste à ne pas coder le nombre entier directement, mais à encoder séparément chaque chiffre de l'alphabet décimal (de 0 à 9) sous la forme d'un mot binaire, puis à juxtaposer (concaténer) ces mots binaires. C'est l'exact équivalent de la numération positionnelle en base 10 : pour former le nombre '123', on juxtaposera le symbole '1', le symbole '2', puis le symbole '3'. Transposé en binaire, si le chiffre 1 possède un code binaire C(1), le chiffre 2 un code C(2), et le chiffre 3 un code C(3), le nombre 123 sera représenté par le bloc binaire continu C(1)C(2)C(3). L'enjeu technique central réside dans le choix de la longueur de ces mots binaires afin de minimiser le volume d'information stocké ou transmis sur un réseau tout en permettant au récepteur de retrouver sans ambiguïté les frontières des chiffres initiaux lors de la lecture du flux continu de bits.

- Concaténation binaire : Assemblage séquentiel de mots binaires représentant chaque chiffre individuel d'un nombre.
- Alphabet décimal : Ensemble des M = 10 symboles fondamentaux à encoder (chiffres de 0 à 9).
- Poids positionnel : Alignement strict de l'ordre d'origine des chiffres pour reconstruire la valeur numérique exacte.

Cas concret enseignant : *L'enseignant illustre le principe avec le nombre 123 : en décimal, c'est la juxtaposition des symboles '1', '2' et '3'. En binaire, si le chiffre 1 a son propre code, le 2 son code, et le 3 son code, coller ces trois blocs bout à bout forme la représentation complète du nombre. La question posée à la classe est alors : combien de bits faut-il attribuer à chaque chiffre ?*

2. Analyse Mathématique Comparée : Format Fixe vs Format Variable Brut

Pour encoder M = 10 symboles distincts (les chiffres décimaux 0 à 9) dans un alphabet binaire de taille 2 ({0, 1}) : - **En Format Fixe** : La capacité d'adressage offerte par N bits est 2^N. Nous cherchons le plus petit entier N tel que 2^N >= 10. Pour N = 3, 2^3 = 8 < 10 (insuffisant). Pour N = 4, 2^4 = 16 >= 10 (valide). Le format fixe impose donc obligatoirement **N = 4 bits par chiffre**. - **En Format Variable Brut** : On cumule l'ensemble des combinaisons offertes par les mots de 1 bit, de 2 bits, jusqu'à N_max bits. Le nombre total de combinaisons disponibles est la somme géométrique : 2^1 + 2^2 + ... + 2^N_max = 2^(N_max+1) - 2. Nous cherchons le plus petit N_max tel que 2^(N_max+1) - 2 >= 10. Pour N_max = 2, 2^3 - 2 = 6 < 10. Pour N_max = 3, 2^4 - 2 = 14 >= 10 (valide). En format variable brut, la longueur maximale requise n'est donc que de **N_max = 3 bits**. Sur le plan théorique pur, le format variable paraît supérieur en compacité puisqu'il ne nécessite au maximum que 3 bits par chiffre là où le format fixe en exige 4 systématiquement.

• Format Fixe : Mots binaires de longueur constante N (Équation de capacité : 2^N >= M).

• Format Variable Brut : Mots binaires de longueurs échelonnées de 1 à N_max bits (Équation : Sum(2^k pour k=1 à N_max) = 2^(N_max+1) - 2 >= M).

• Cardinalité de l'alphabet binaire : Taille de l'alphabet de codage |L| = 2 (symboles 0 et 1).

Cas concret enseignant : *Le professeur écrit les deux formules au tableau et démontre que pour N_max = 3 en format variable, on dispose de 2 mots de 1 bit (0, 1), 4 mots de 2 bits (00, 01, 10, 11) et 8 mots de 3 bits (000 à 111), ce qui génère 2 + 4 + 8 = 14 combinaisons disponibles, soit plus qu'il n'en faut pour nos 10 chiffres décimaux.*

3. Le Dilemme Compacité vs Décodabilité : L'Ambiguïté de Découpage (Framing)

La comparaison entre les deux formats met en évidence un compromis fondamental en informatique entre compacité d'information et simplicité de traitement : - **En Format Fixe (4 bits)**, le découpage à la réception est déterministe et immédiat : sachant que chaque mot fait 4 bits, la machine réceptrice découpe le flux continu reçu par tranches de 4 bits (bits 1 à 4 = 1er chiffre, bits 5 à 8 = 2ème chiffre, etc.) et reconstruit la valeur sans la moindre hésitation. - **En Format Variable Brut**, le flux binaire transmis ne comporte aucun délimiteur d'espace. Si un mot peut faire 1, 2 ou 3 bits, plusieurs découpages deviennent théoriquement et pratiquement valides pour un même flux de bits. Le récepteur n'a aucun moyen logique d'identifier où s'arrête le premier chiffre et où commence le suivant. Le message est entaché d'une ambiguïté bloquante qui le rend inexploitable.

• Framing / Découpage : Capacité du processeur récepteur à identifier sans ambiguïté les limites de chaque mot binaire dans un flux continu.

• Ambiguïté de décodage : Perte d'unicité de l'interprétation d'un flux binaire due à l'absence de frontières claires entre les mots.

• Avantage du Format Fixe : Découpage trivial et déterministe par tranches de taille constante N.

Cas concret enseignant : *Le professeur utilise une métaphore marquante : lorsqu'on envoie le flux binaire codant 123 en format variable brut sans délimiteur, à la réception le processeur « est comme un couillon ». En effet, la séquence binaire reçue peut être découpée et lue comme étant le nombre 123, mais tout aussi bien comme le nombre 1212 ou encore 33 ! Sans règle de séparation, l'ordinateur est incapable de trancher.*

4. Levée d'Ambiguïté par Codes Auto-délimités et Calcul de Longueur Moyenne

Pour concilier la compacité du format variable et le décodage sans ambiguïté du format fixe, on construit des **codes à longueur variable auto-délimités**. L'idée consiste à imposer une règle syntaxique de rupture dans la structure même des bits. Exemple de règle analysée en cours : *« Dès que le motif binaire '10' est rencontré dans le flux, le mot binaire s'arrête impérativement au bit qui suit directement ce motif (avec une longueur maximale plafonnée à 5 bits) »*. En appliquant cette règle pour générer 10 mots binaires uniques attribués aux 10 chiffres décimaux (0 à 9), la somme totale des longueurs des 10 mots du dictionnaire s'élève à 38 bits. La longueur moyenne statistique par chiffre s'établit alors à : L_moyen = 38 / 10 = 3,8 bits par chiffre. **Bilan comparatif :** - Format Fixe = 4,0 bits/chiffre. - Format Variable Auto-délimité = 3,8 bits/chiffre. - Gain de compacité = (4,0 - 3,8) / 4,0 = 0,05 soit **5% d'économie** d'espace mémoire et de bande passante réseau, tout en garantissant un décodage 100% déterministe et instantané à la volée.

• Code auto-délimité (Code préfixe) : Code à longueur variable conçu de telle sorte que la fin de chaque mot est détectée de façon univoque sans séparateur externe.

• Règle de rupture / d'arrêt : Condition syntaxique imposée sur la structure des bits (ex: arrêt immédiat au bit suivant le motif '10').

• Longueur moyenne (L_moyen) : Somme des longueurs de tous les mots du dictionnaire divisée par le nombre total de symboles (M = 10).

Cas concret enseignant : *L'enseignant fait effectuer le calcul de la somme des longueurs des 10 mots générés par la règle : 5 + 10 + 15... = 38 bits au total pour 10 symboles, soit 3,8 bits/chiffre en moyenne. Il conclut : « Même si nous sommes légèrement au-dessus des 3 bits théoriques du format variable brut, nous battons le format fixe de 4 bits avec 5% d'économie tout en sachant décoder parfaitement à la volée ! »*

■ Questions & Interventions des Étudiants en Classe

Question étudiant : Quel est l'avantage du format fixe si le format variable permet théoriquement d'avoir des mots binaires plus courts (longueur maximale de 3 bits contre 4 bits fixes) ?
Réponse du professeur : L'avantage absolu du format fixe réside dans la simplicité et le caractère déterministe du découpage (framing). Connaissant la règle (4 bits par chiffre), le récepteur découpe le flux continu par tranches fixes de 4 bits et lit les chiffres sans aucune ambiguïté. Le format variable brut, lui, est indécodable car le récepteur ne sait pas où trancher.

Question étudiant : Dans la règle de délimitation proposée ('dès qu'on rencontre 10, on s'arrête au bit suivant'), comment s'applique l'arrêt pour le 3ème cas ou lorsque la longueur maximale de 5 bits est atteinte ?
Réponse du professeur : La règle de rupture syntaxique sur le motif '10' déclenche l'arrêt immédiat au bit suivant. Si le motif n'apparaît pas ou si la limite imposée (plafond de 5 bits) est atteinte, l'automate de lecture sait exactement qu'il doit arrêter le mot binaire en cours. Cela garantit que chaque combinaison reste unique et repérable à la volée sans séparateur externe.

■ Exercice & Démonstration d'Application

Énoncé : On souhaite encoder l'alphabet des M = 10 chiffres décimaux (0 à 9) pour les transmettre sous forme de flux binaire continu. 1. Calculer le nombre de bits minimal N requis en Format Fixe. 2. Calculer la longueur maximale N_max théorique en Format Variable Brut. 3. Soit un code variable auto-délimité dont les mots associés aux 10 chiffres ont pour longueurs respectives : [2, 3, 3, 4, 4, 4, 4, 4, 5, 5] bits. Calculer la longueur moyenne par chiffre (L_moyen) et le pourcentage de gain de stockage obtenu par rapport au format fixe.

Démarche de résolution :
Étape 1 : Format Fixe On cherche le plus petit entier N tel que 2^N >= M (avec M = 10). - Pour N = 3 : 2^3 = 8 < 10 (insuffisant). - Pour N = 4 : 2^4 = 16 >= 10 (valide). Conclusion : N = 4 bits par chiffre. Étape 2 : Format Variable Brut On cherche le plus petit N_max tel que Sum(2^k pour k de 1 à N_max) = 2^(N_max + 1) - 2 >= 10. - Pour N_max = 2 : 2^(2+1) - 2 = 8 - 2 = 6 < 10 (insuffisant). - Pour N_max = 3 : 2^(3+1) - 2 = 16 - 2 = 14 >= 10 (valide). Conclusion : N_max = 3 bits. Étape 3 : Longueur Moyenne et Gain de Compacité - Somme des longueurs des 10 mots = 2 + 3 + 3 + 4 + 4 + 4 + 4 + 4 + 5 + 5 = 38 bits au total. - Longueur moyenne L_moyen = 38 / 10 = 3,8 bits par chiffre. - Gain relatif par rapport au format fixe (4 bits) : Gain = (N_fixe - L_moyen) / N_fixe = (4 - 3,8) / 4 = 0,2 / 4 = 0,05 soit 5%.

Résultat : Format fixe : 4 bits/chiffre | Format variable brut max : 3 bits | Format variable auto-délimité : 3,8 bits/chiffre en moyenne. Le code auto-délimité offre un gain de 5% de bande passante et de mémoire par rapport au format fixe, tout en éliminant 100% des ambiguïtés au décodage.

■ Auto-Évaluation Flash d'Examen

Q : Quelle est l'équation mathématique permettant de déterminer le nombre de bits N en format fixe pour encoder M symboles distincts ?

R : L'inéquation est 2^N >= M. Pour M = 10 chiffres décimaux, le plus petit entier N valide est N = 4 bits (car 2^3 = 8 < 10 et 2^4 = 16 >= 10).

Q : Pourquoi la capacité totale d'un format variable de longueur maximale N_max s'exprime-t-elle par la formule 2^(N_max + 1) - 2 ?

R : Car c'est la somme d'une suite géométrique représentant le cumul des combinaisons de tous les niveaux de longueur : 2^1 + 2^2 + ... + 2^N_max = 2^(N_max + 1) - 2.

Q : Quel est le problème fondamental d'un codage en format variable brut et comment un code auto-délimité le résout-il ?

R : Le format variable brut supprime les frontières entre les mots binaires dans le flux continu (perte de framing), rendant le message ambigu et indécodable. Un code auto-délimité résout ce problème en introduisant une règle syntaxique de rupture (ex: motif d'arrêt) permettant au récepteur de détecter la fin de chaque mot à la volée sans séparateur externe.