Représentation et Codage Binaire des Chiffres Décimaux : Format Fixe, Format Variable Brut et Codes Auto-délimités

Thème principal : Codage de l'information, théorème de capacité et levée d'ambiguïté au décodage (Framing)

Synthèse exécutive : Ce cours traite de la problématique fondamentale de la représentation informatique des nombres décimaux à plusieurs chiffres en encodant séparément chaque chiffre (de 0 à 9) avant de les concaténer. Nous analysons et comparons deux structures fondamentales de mots binaires : le Format Fixe (où chaque mot possède la même longueur N) et le Format Variable Brut (où les mots ont des longueurs échelonnées jusqu'à une longueur maximale N_max). Sur le plan théorique, le format fixe impose N = 4 bits par chiffre (via 2^N >= 10), alors que le format variable permet théoriquement d'atteindre une longueur maximale N_max = 3 bits seulement (via 2^(N_max+1) - 2 >= 10). Cependant, le format variable brut supprime les frontières entre les mots binaires, rendant le flux continu totalement ambigu et indécodable à la réception. Pour surmonter ce blocage tout en conservant une compacité optimale, le cours démontre la construction de codes à longueur variable auto-délimités (codes préfixes) basés sur une règle syntaxique de rupture sur motif (ex. arrêt au bit suivant la rencontre du motif '10'). Cette méthode permet d'obtenir un décodage exact et déterministe avec une longueur moyenne statistique de 3,8 bits par chiffre, réalisant un gain de 5% d'espace mémoire et de bande passante par rapport au format fixe.

Principe de Codage Décimal par Concaténation Binaire

Pour représenter de grands nombres décimaux dans une architecture informatique, l'une des approches les plus directes consiste à ne pas coder le nombre entier dans son ensemble, mais à encoder individuellement chaque chiffre de l'alphabet décimal (de 0 à 9) sous la forme d'un mot binaire, puis à juxtaposer (concaténer) ces mots binaires. C'est l'exact équivalent de notre numération de position en base 10 : pour former le nombre '123', on juxtapose le symbole '1', le symbole '2', puis le symbole '3'. Transposé en binaire, si le chiffre 1 possède un mot binaire attribué C(1), le chiffre 2 un mot C(2), et le chiffre 3 un mot C(3), le nombre 123 sera représenté par la séquence binaire continue C(1)C(2)C(3). L'enjeu technique central réside dans le choix de la longueur de ces mots binaires afin de minimiser le volume d'information stocké en mémoire ou transmis sur un réseau, tout en permettant au récepteur de retrouver sans ambiguïté les frontières des chiffres initiaux lors de la lecture du flux continu de bits.

- Concaténation binaire : Juxtaposition séquentielle des mots binaires codant chaque chiffre décimal individuel d'un nombre.
- Alphabet décimal : Ensemble des M = 10 symboles de base (chiffres de 0 à 9) à représenter.
- Poids positionnel : Alignement strict de l'ordre d'origine des chiffres pour reconstruire exactement le nombre d'origine (ex: 123).

Cas concret enseignant : *Le professeur illustre le principe au tableau avec le nombre 123 : en décimal, c'est la juxtaposition des symboles '1', '2' et '3'. En binaire, si le chiffre 1 a son propre code, le 2 son code, et le 3 son code, coller ces trois blocs bout à bout forme la représentation complète du nombre. La question posée à la classe est alors : combien de bits faut-il attribuer à chaque chiffre ?*

Analyse Mathématique Comparée : Format Fixe vs Format Variable Brut

Pour encoder M = 10 symboles distincts (les chiffres décimaux de 0 à 9) avec un alphabet binaire (base 2) : 1. En Format Fixe : Chaque symbole est représenté par un mot de même longueur N. Le nombre de combinaisons distinctes offertes par N bits est 2^N. Il faut déterminer le plus petit entier N respectant l'inéquation 2^N >= 10. Pour N = 3, 2^3 = 8 < 10 (insuffisant pour 10 chiffres). Pour N = 4, 2^4 = 16 >= 10 (valide). Le format fixe impose donc obligatoirement N = 4 bits par chiffre. 2. En Format Variable Brut : On s'autorise à utiliser des mots de 1 bit, de 2 bits, jusqu'à une longueur maximale N_max bits. La capacité totale de codage correspond à la somme des combinaisons de chaque niveau : 2^1 + 2^2 + ... + 2^N_max, ce qui équivaut à la somme géométrique 2^(N_max+1) - 2. On cherche le plus petit N_max tel que 2^(N_max+1) - 2 >= 10. Pour N_max = 2, 2^3 - 2 = 6 < 10.

Pour N_max = 3, 2^4 - 2 = 14 >= 10 (valide). En format variable brut, la longueur maximale requise n'est donc que de N_max = 3 bits. Sur le plan théorique pur, le format variable paraît supérieur en compacité puisqu'il ne nécessite au maximum que 3 bits par chiffre là où le format fixe en exige 4 systématiquement.

- Format Fixe : Tous les mots binaires associés aux M symboles ont rigoureusement la même longueur N bits (Équation : 2^N >= M).
- Format Variable Brut : Les mots binaires ont des longueurs échelonnées de 1 bit à N_max bits (Équation de capacité : Sum(2^k pour k=1 à N_max) = 2^(N_max+1) - 2 >= M).
- Cardinalité de l'alphabet binaire : Taille de l'alphabet de codage |L| = 2 (les symboles 0 et 1).

Cas concret enseignant : *Le professeur écrit les deux formules au tableau et montre que pour N_max = 3 en format variable, on dispose de 2 mots de 1 bit (0, 1), 4 mots de 2 bits (00, 01, 10, 11) et 8 mots de 3 bits (000 à 111), ce qui génère 2 + 4 + 8 = 14 combinaisons disponibles, soit plus qu'il n'en faut pour nos 10 chiffres décimaux.*

Le Dilemme Compacité vs Décodabilité : L'Ambiguïté de Découpage (Framing)

La comparaison entre les deux formats met en évidence un compromis fondamental en informatique entre compacité d'information et simplicité de traitement : - En Format Fixe (4 bits), le découpage à la réception est déterministe et immédiat : sachant que chaque mot fait 4 bits, la machine réceptrice découpe le flux continu reçu par tranches strictes de 4 bits (bits 1 à 4 = 1er chiffre, bits 5 à 8 = 2ème chiffre, etc.) et reconstruit la valeur d'origine sans la moindre hésitation. - En Format Variable Brut, le flux binaire transmis ne comporte aucun délimiteur d'espace. Si un mot peut faire 1, 2 ou 3 bits, plusieurs découpages deviennent théoriquement et pratiquement valides pour un même flux de bits. Le récepteur n'a aucun moyen logique d'identifier où s'arrête le premier chiffre et où commence le suivant. Le message est entaché d'une ambiguïté bloquante qui le rend inexploitable.

- Framing / Découpage : Capacité du processeur récepteur à identifier sans ambiguïté les limites de chaque mot binaire dans un flux continu.
- Ambiguïté de décodage : Perte d'unicité de l'interprétation d'un flux binaire due à l'absence de frontières claires entre les mots.
- Avantage du Format Fixe : Découpage trivial et déterministe par tranches de taille constante N.

Cas concret enseignant : *Le professeur utilise une métaphore marquante : lorsqu'on envoie le flux binaire codant 123 en format variable brut sans délimiteur, à la réception le processeur « est comme un couillon ». En effet, la séquence binaire reçue peut être découpée et lue comme étant le nombre 123, mais tout aussi bien comme le nombre 1212 ou encore 33 ! Sans règle de séparation, l'ordinateur est incapable de trancher.*

Levée d'Ambiguïté par Codes Auto-délimités et Calcul de Longueur Moyenne

Pour concilier la compacité du format variable et le décodage sans ambiguïté du format fixe, on construit des codes à longueur variable auto-délimités. L'idée consiste à imposer une règle syntaxique de rupture dans la structure même des bits. Exemple de règle analysée en cours : *« Dès que le motif binaire '10' est rencontré dans le flux, le mot binaire s'arrête impérativement au bit qui suit directement ce motif (avec une longueur maximale plafonnée à 5 bits) »*. En appliquant cette règle pour générer 10 mots binaires uniques attribués aux 10 chiffres décimaux (0 à 9), la somme totale des longueurs des 10 mots du dictionnaire s'élève à 38 bits. La longueur moyenne statistique par chiffre s'établit alors à : L_moyen = 38 / 10 = 3,8 bits par chiffre. Bilan comparatif : - Format Fixe = 4,0 bits/chiffre. - Format Variable Auto-délimité = 3,8 bits/chiffre. - Gain de compacité = (4,0 - 3,8) / 4,0 = 0,05 soit 5% d'économie d'espace mémoire et de bande passante réseau, tout en garantissant un décodage 100% déterministe et instantané à la volée.

- Code auto-délimité (Code préfixe) : Code à longueur variable conçu de telle sorte que la fin de chaque mot est détectée de façon univoque sans séparateur externe.
- Règle de rupture / d'arrêt : Condition syntaxique imposée sur la structure des bits (ex: arrêt immédiat au bit suivant le motif '10').
- Longueur moyenne (L_moyen) : Somme des longueurs de tous les mots du dictionnaire divisée par le nombre total de symboles (M = 10).

Cas concret enseignant : *L'enseignant fait effectuer le calcul de la somme des longueurs des 10 mots générés par la règle : 5 + 10 + 15... = 38 bits au total pour 10 symboles, soit 3,8 bits/chiffre en moyenne. Il conclut : « Même si nous sommes légèrement au-dessus des 3 bits théoriques du format variable brut, nous battons le format fixe de 4 bits avec 5% d'économie tout en sachant décoder parfaitement à la volée ! »*

■ Questions & Interventions des Étudiants en Classe

Question étudiant : Quel est l'avantage précis du format fixe par rapport au format variable si ce dernier offre des mots d'une longueur maximale plus courte ?
Réponse du professeur : L'avantage majeur du format fixe réside dans la simplicité et le caractère déterministe du découpage (framing). Sachant que chaque chiffre fait exactement 4 bits, la machine réceptrice n'a qu'à couper le flux continu tous les 4 bits sans aucun risque d'ambiguïté. À l'inverse, en format variable brut sans délimiteur, la machine ne sait pas où séparer les chiffres (le processeur 'est comme un couillon' face à un flux qui peut signifier 123, 1212 ou 33).

Question étudiant : Dans l'application de la règle de délimitation ('dès qu'on rencontre 10, on s'arrête au bit suivant'), pourquoi certains mots s'arrêtent-ils plus tôt ou atteignent-ils la longueur maximale de 5 bits ?
Réponse du professeur : La règle syntaxique impose une condition de rupture dès la lecture de la séquence '10' suivie de son bit adjacent. Si cette séquence apparaît précoce dans le mot, la fin du symbole est décrétée immédiatement. Si la séquence n'apparaît pas, le mot est limité par la longueur maximale autorisée (5 bits ici). Cela garantit que chaque mot binaire se différencie de manière univoque sans avoir besoin d'insérer des bits de séparation externes.

■ Exercice & Démonstration d'Application

Énoncé : On souhaite encoder l'alphabet des M = 10 chiffres décimaux (0 à 9) pour les transmettre sous forme de flux binaire continu. 1. Calculer le nombre de bits minimal N requis en Format Fixe. 2. Calculer la longueur maximale N_max théorique en Format Variable Brut. 3. Soit un code variable auto-délimité dont les mots associés aux 10 chiffres ont pour longueurs respectives : [2, 3, 3, 4, 4, 4, 4, 4, 5, 5] bits. Calculer la longueur moyenne par chiffre (L_moyen) et le pourcentage de gain de stockage obtenu par rapport au format fixe.

Démarche de résolution :
Étape 1 : Format Fixe On cherche le plus petit entier N tel que 2^N >= M (avec M = 10). - Pour N = 3 : 2^3 = 8 < 10 (insuffisant). - Pour N = 4 : 2^4 = 16 >= 10 (valide). Conclusion : N = 4 bits par chiffre en format fixe. Étape 2 : Format Variable Brut On cherche le plus petit N_max tel que Sum(2^k pour k de 1 à N_max) = 2^(N_max + 1) - 2 >= 10. - Pour N_max = 2 : 2^(2+1) - 2 = 8 - 2 = 6 < 10 (insuffisant). - Pour N_max = 3 : 2^(3+1) - 2 = 16 - 2 = 14 >= 10 (valide). Conclusion : N_max = 3 bits en format variable brut. Étape 3 : Longueur Moyenne et Gain de Compacité - Somme des longueurs des 10 mots = 2 + 3 + 3 + 4 + 4 + 4 + 4 + 4 + 5 + 5 = 38 bits au total. - Longueur moyenne L_moyen = 38 / 10 = 3,8 bits par chiffre. - Gain de compacité relatif par rapport au format fixe (4 bits) : Gain = (N_fixe - L_moyen) / N_fixe = (4 - 3,8) / 4 = 0,2 / 4 = 0,05 soit 5%.

Résultat : Format fixe : 4 bits/chiffre | Format variable brut max : 3 bits | Format variable auto-délimité : 3,8 bits/chiffre en moyenne. Le code auto-délimité offre un gain de 5% de bande passante et d'espace mémoire par rapport au format fixe, tout en garantissant un décodage 100% déterministe et sans ambiguïté.

■ Auto-Évaluation Flash d'Examen

Q : Quelle est l'équation mathématique permettant de déterminer le nombre de bits N requis en format fixe pour encoder M symboles distincts ?

R : L'inéquation est 2^N >= M. Pour M = 10 chiffres décimaux, le plus petit entier satisfaisant est N = 4 bits (car 2^3 = 8 < 10 et 2^4 = 16 >= 10).

Q : Pourquoi la capacité d'adressage totale d'un format variable brut de longueur maximale N_max s'exprime-t-elle par la formule 2^(N_max + 1) - 2 ?

R : Parce qu'elle résulte de la somme de la suite géométrique des combinaisons offertes par les mots de 1 bit, 2 bits, ..., jusqu'à N_max bits : Sum(2^k pour k de 1 à N_max) = 2^1 + 2^2 + ... + 2^N_max = 2^(N_max + 1) - 2.

Q : Quel est le problème fondamental d'un codage en format variable brut sans délimiteur et comment un code auto-délimité le résout-il ?

R : Le problème est l'ambiguïté de découpage (perte du framing) à la réception, car le récepteur ne sait pas où se situent les frontières de mots. Un code auto-délimité résout ce problème en intégrant une règle syntaxique de rupture (code préfixe) dans la structure des bits, permettant au récepteur de détecter la fin d'un mot à la volée sans séparateur externe.

Fiche académique générée et vérifiée par Kai pour Matéi • Hébergée sur http://88.96.47.180:8765