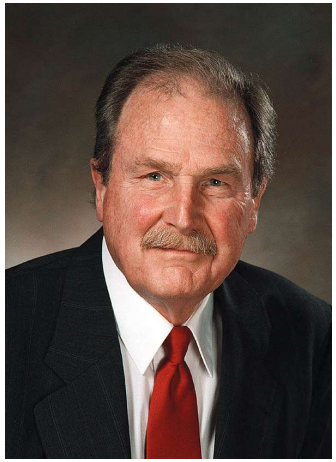


Huffman



Shannon

TD2

Compression par codage

Codage

On veut coder des très grands nombres décimaux en binaire en occupant le moins de place possible. On choisit de coder les chiffres par un langage binaire puis de concaténer les codes.

1. Taille de mots binaires pour coder les chiffres en format fixe et en format variable.

2. Combien de bits faut-il pour coder un nombre de N chiffres ?

3. Quels sont les avantages et inconvénients de chacun de ces deux codages pour ce que l'on veut faire ?
   Doit-on choisir un format de mots binaire fixe ou variable ?
   Pourquoi ?

Codage

Pour éviter le problème lié au format variable : celui de la coupure des mots tout en conservant l'avantage du gain de place, on peut utiliser un langage binaire à format variable avec des règles permettant d'effectuer les coupures sans ambiguïté.

1. Proposer un langage binaire avec une longueur de mots maximale de 5 avec des règles permettant d'effectuer les coupures sans ambiguïté **et ayant au moins 10 mots**.

Codage choisi

On choisit le langage que l'on vient de trouver :

{ 00 , 01 , 100 , 101 , 1100 , 1101 , 11100 , 11101 , 11110 , 11111 }

pour représenter les 10 chiffres.

1. Quelle sera la taille moyenne en bits de la représentation d'un nombre de N chiffres ?

2. La comparer avec celle nécessaire en utilisant un format fixe pour coder les chiffres.

Codage futé

Avec notre langage on veut représenter le nombre :

194 796 524 930 401

1. Faire une assignation sémantique permettant d'obtenir le code binaire le plus court possible.

2. Comparer la taille du mot binaire obtenue à la moyenne calculée précédemment et à celle obtenue en format fixe

Ce que l'on veut faire

- Quand on veut gagner de la place on peut utiliser des algorithmes de compression (genre ZIP) qui utilisent du format variable en se débrouillant pour pouvoir séparer et en choisissant l'assignation sémantique optimale.

- On gagne pas mal de place mais on perd un peu de temps à décoder

Codage de Huffman

Huffman propose une méthode permettant de fabriquer un langage en format variable séparable avec une assignation sémantique optimale en fonction de ce que l'on veut coder.

Voici sur une exemple comment il procède :

Exemple de la méthode de Huffman

On veut compacter la chaîne
"ABACFGABDDACECG"

1. On classe les lettres par ordre d'occurrence dans la chaîne :

lettre	occurrences
A	4
B	2
C	3
D	2
E	1
F	1
G	2

Etape 1

A —— 4

C —— 3

B —— 2

D —— 2

G —— 2

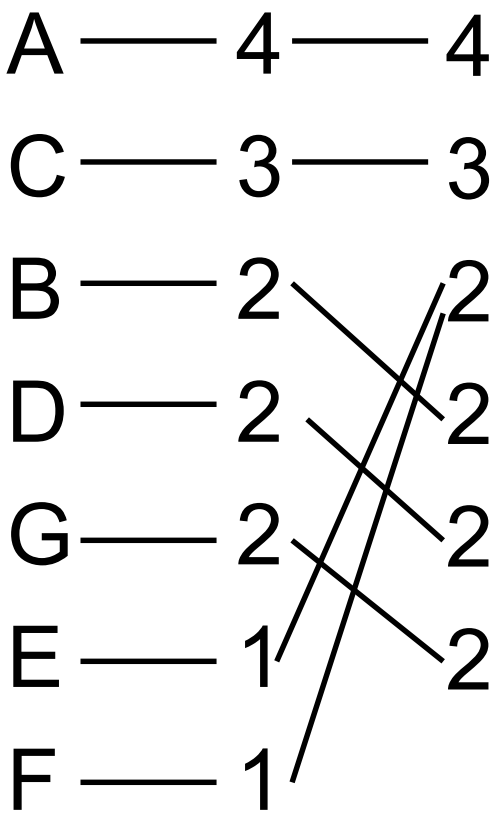
E —— 1

F —— 1

On fait un arbre classant les lettres par ordre d'occurrence.

lettre	occurrences
A	4
B	2
C	3
D	2
E	1
F	1
G	2

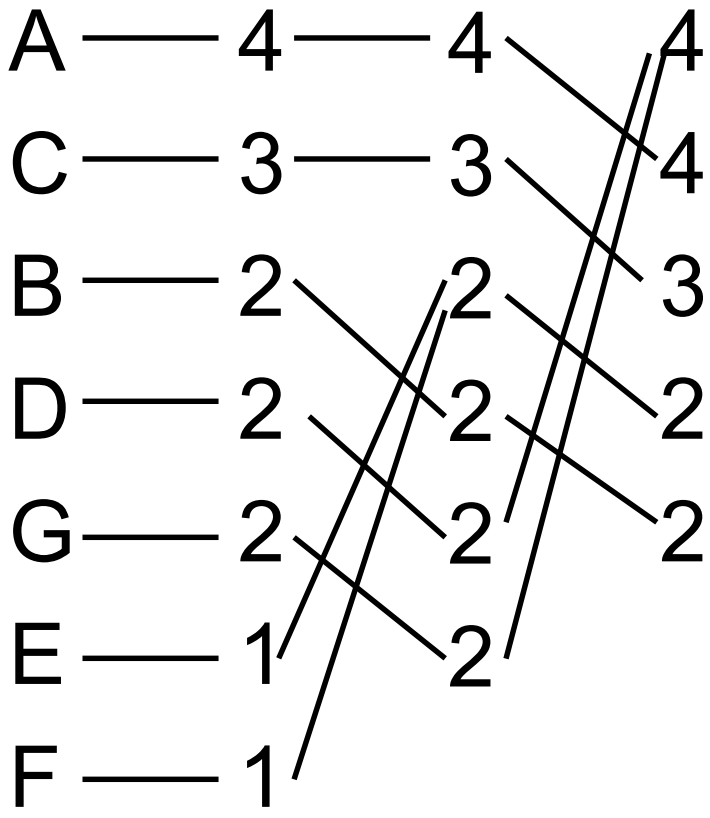
Etape 2



On fait la somme des 2 occurrences les plus faibles et on reclasse le valeurs obtenues.

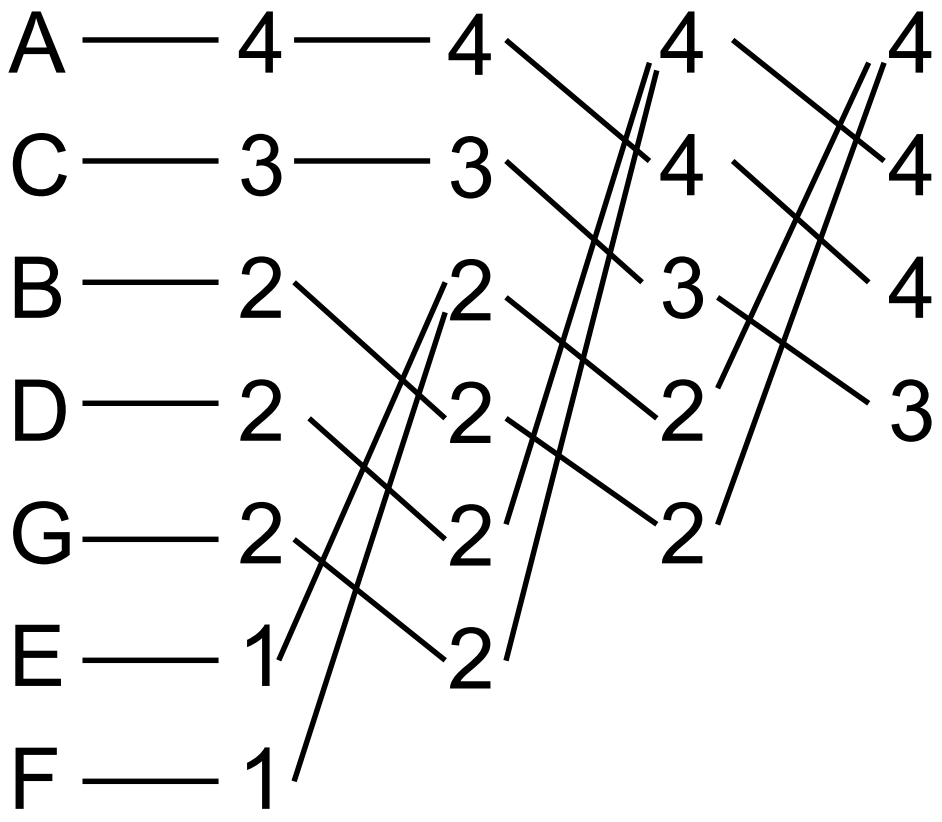
Les autres restent inchangées

Etape 3



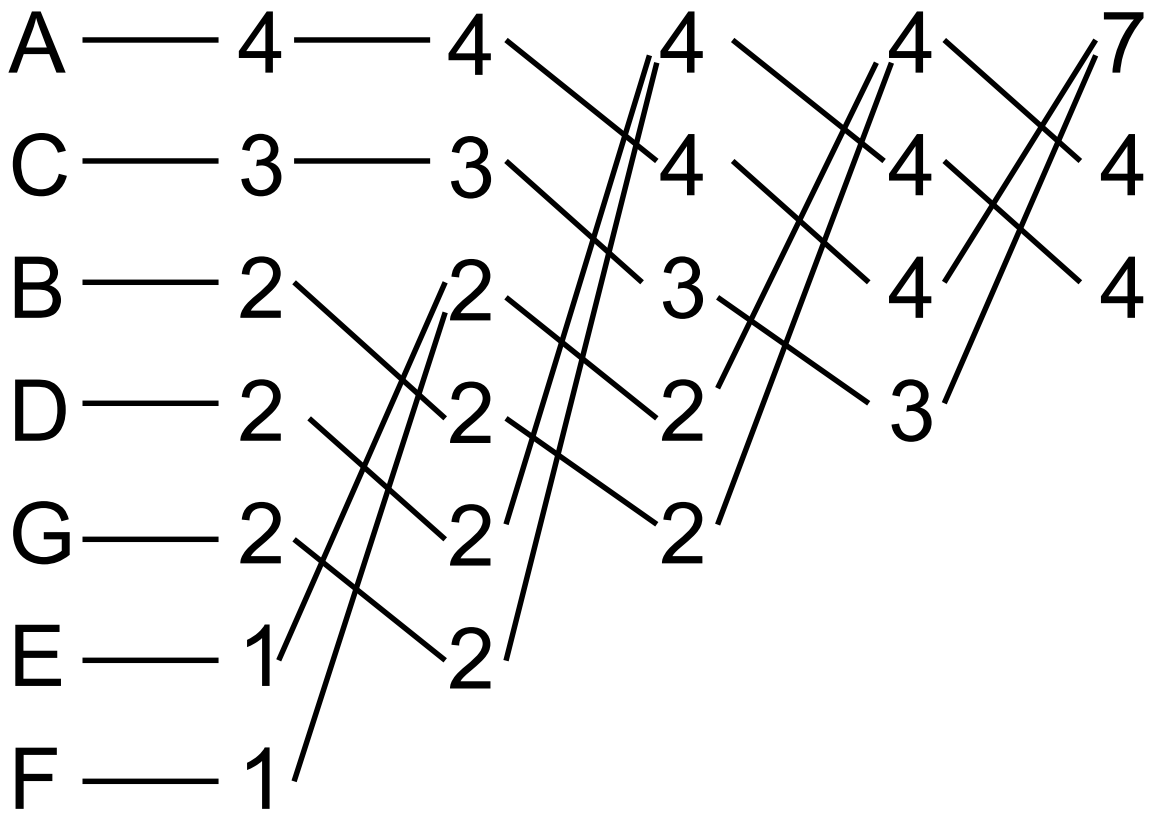
On recommence avec les 2 occurrences les plus faibles .

Etape 4

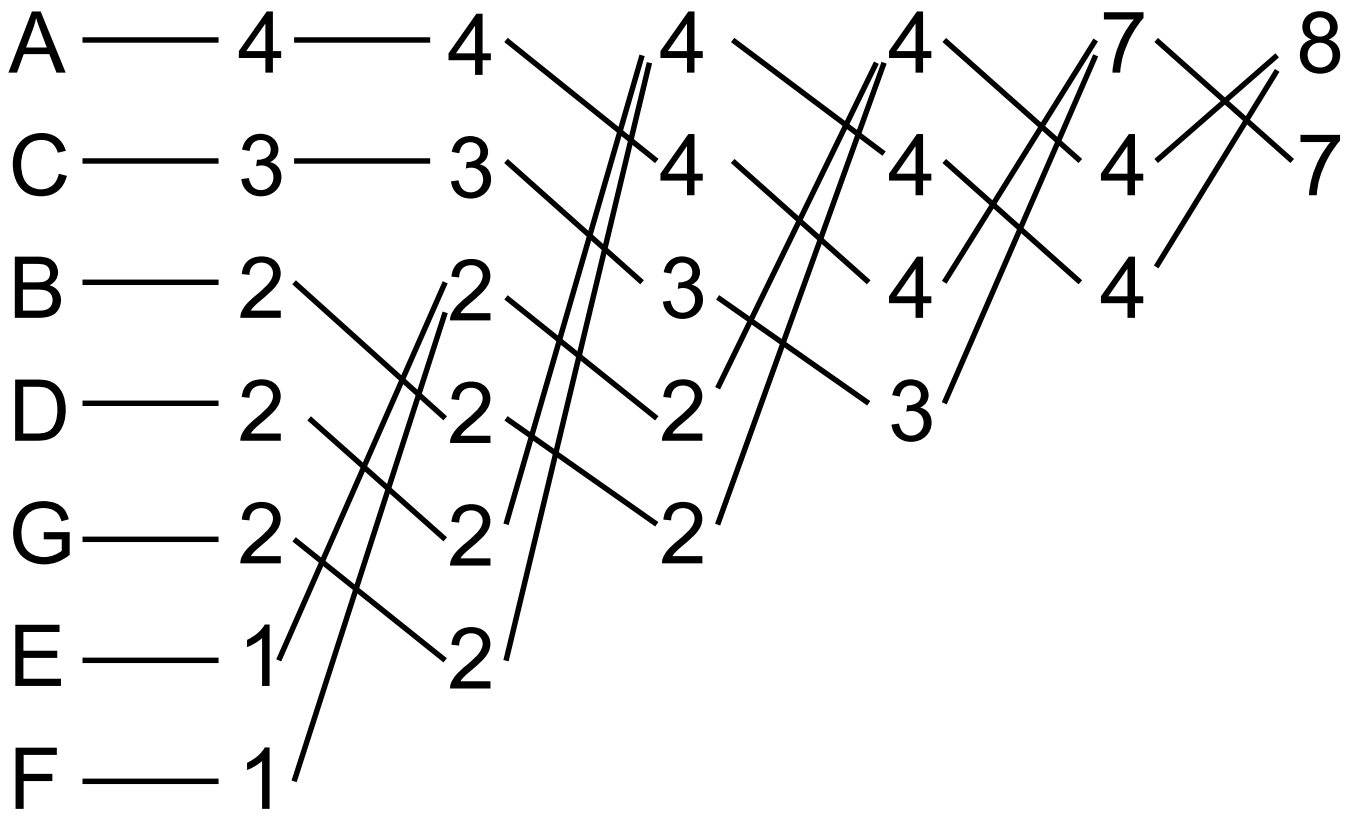


On recommence avec les 2 occurrences les plus faibles .

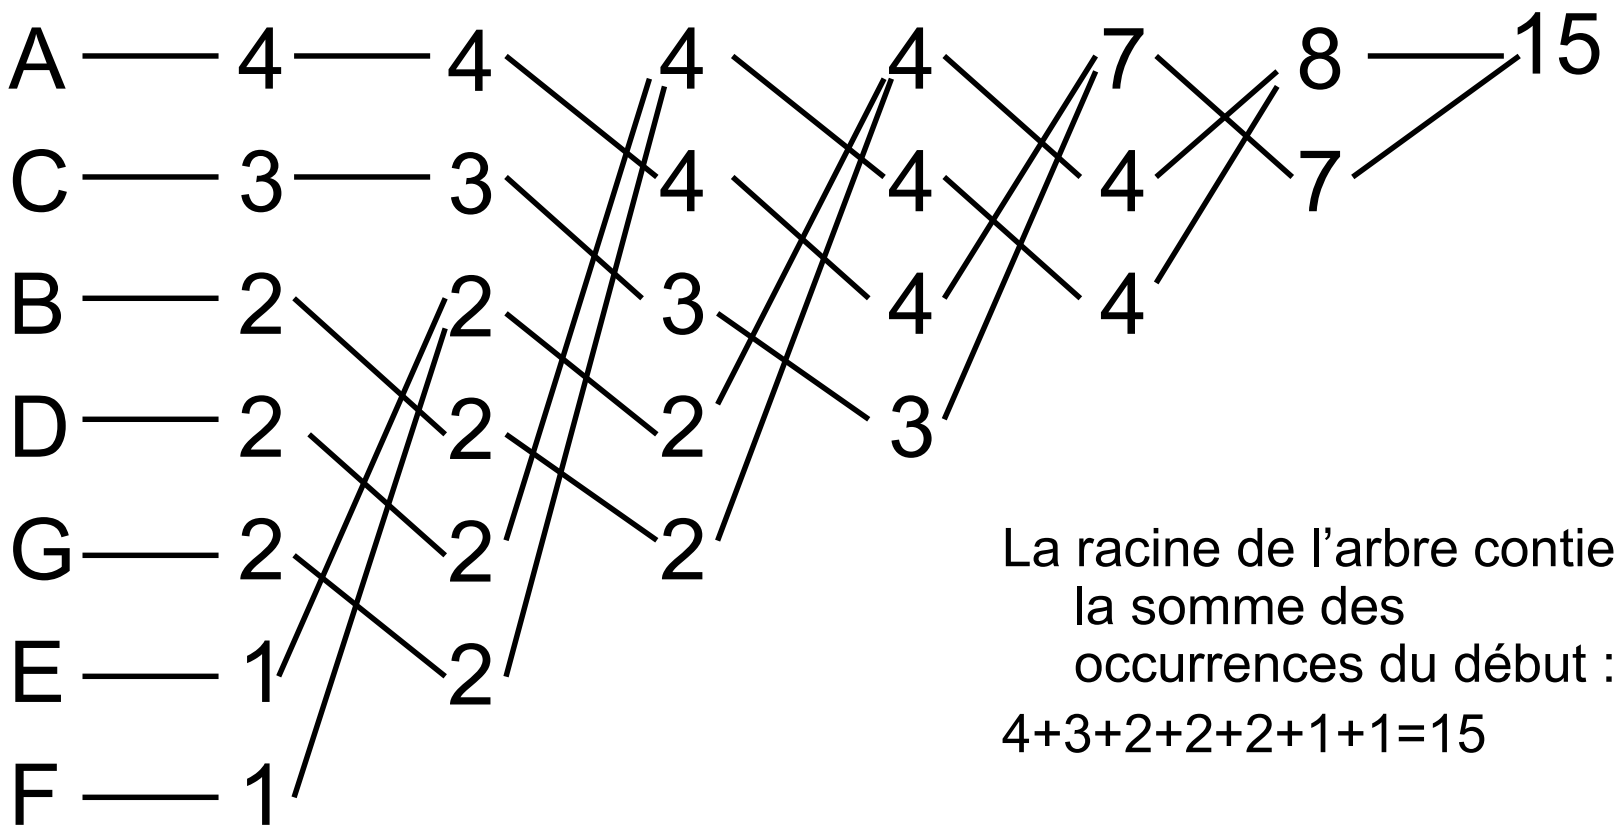
Etape 5



Etape 6



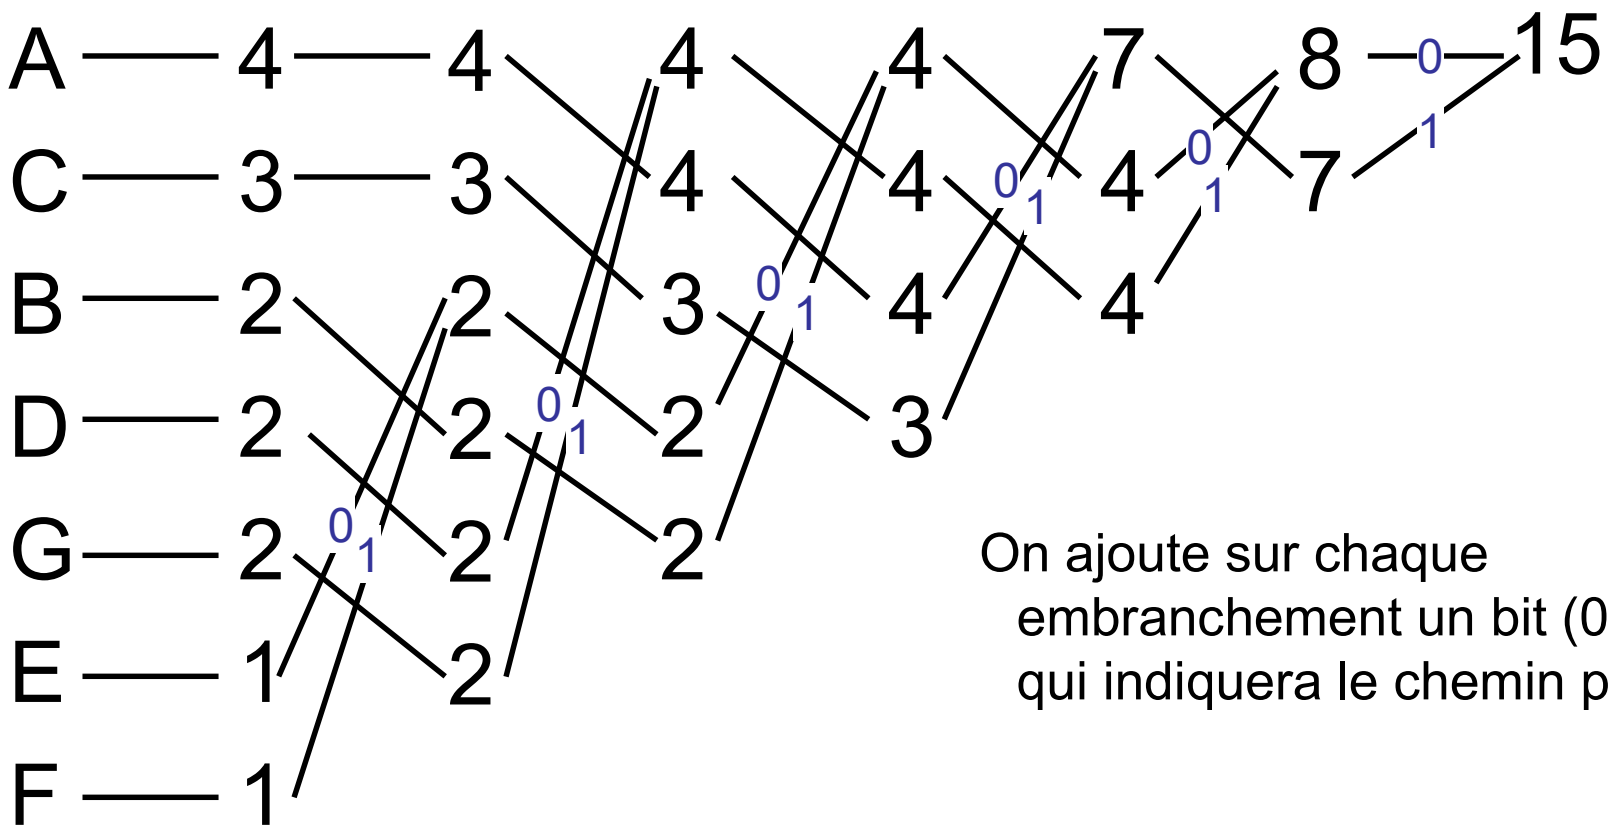
Etape 7



La racine de l'arbre contient la somme des occurrences du début :

4+3+2+2+2+1+1=15

Etape 8



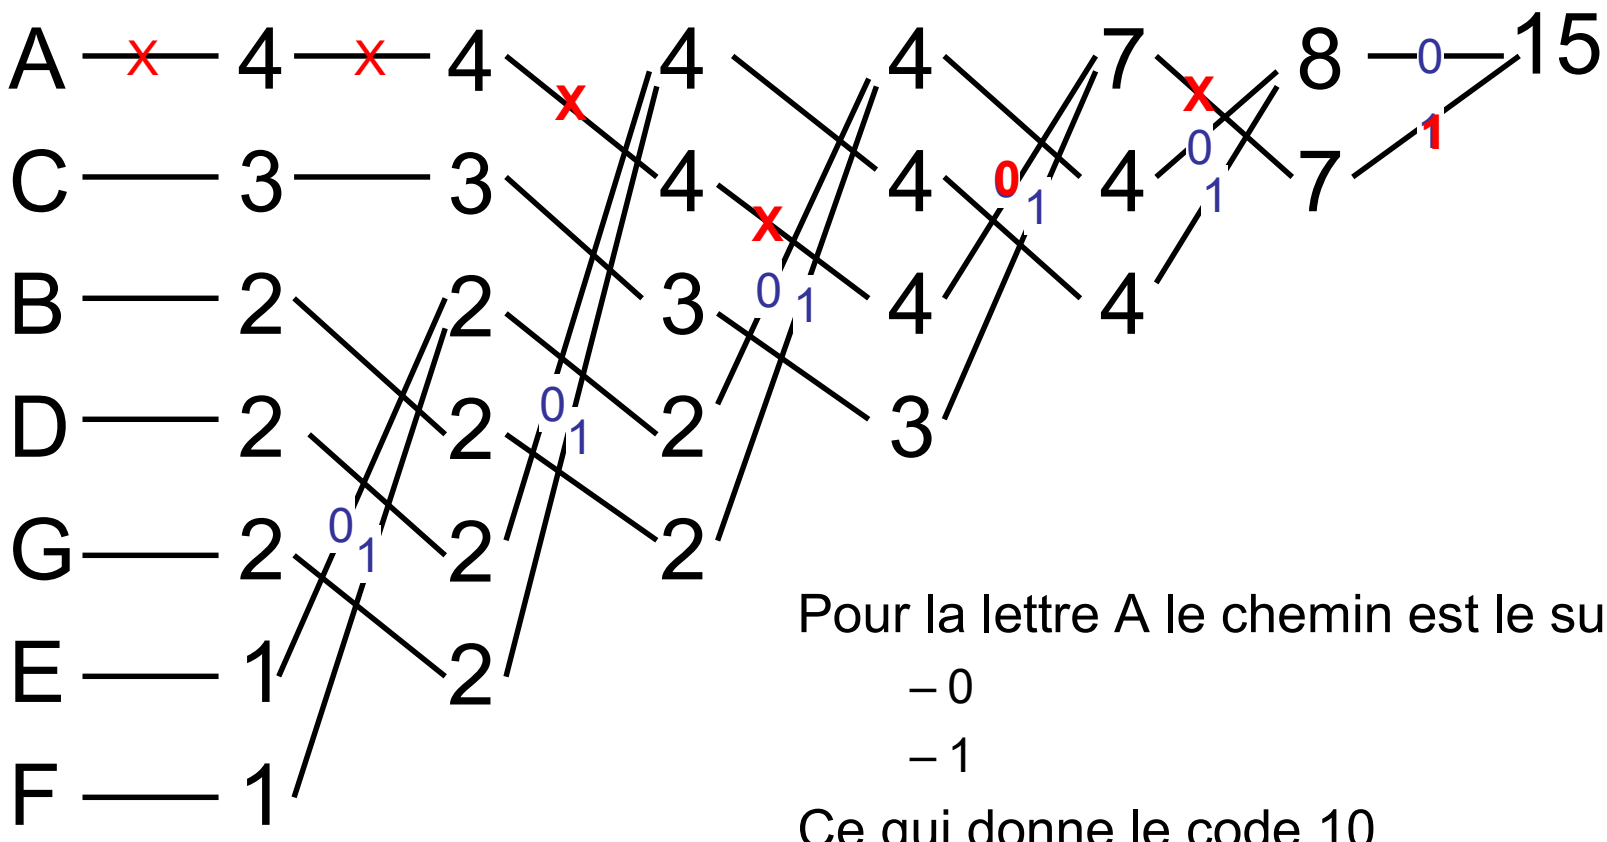
On ajoute sur chaque embranchement un bit (0 ou 1) qui indiquera le chemin pris

Méthode

- On lit alors les codes (de droite à gauche) de la racine de l'arbre vers la feuille en lisant le code (0 ou 1) associé à chaque choix d'embranchement.

- Ce qui nous donne le codage suivant :

Lecture des codes

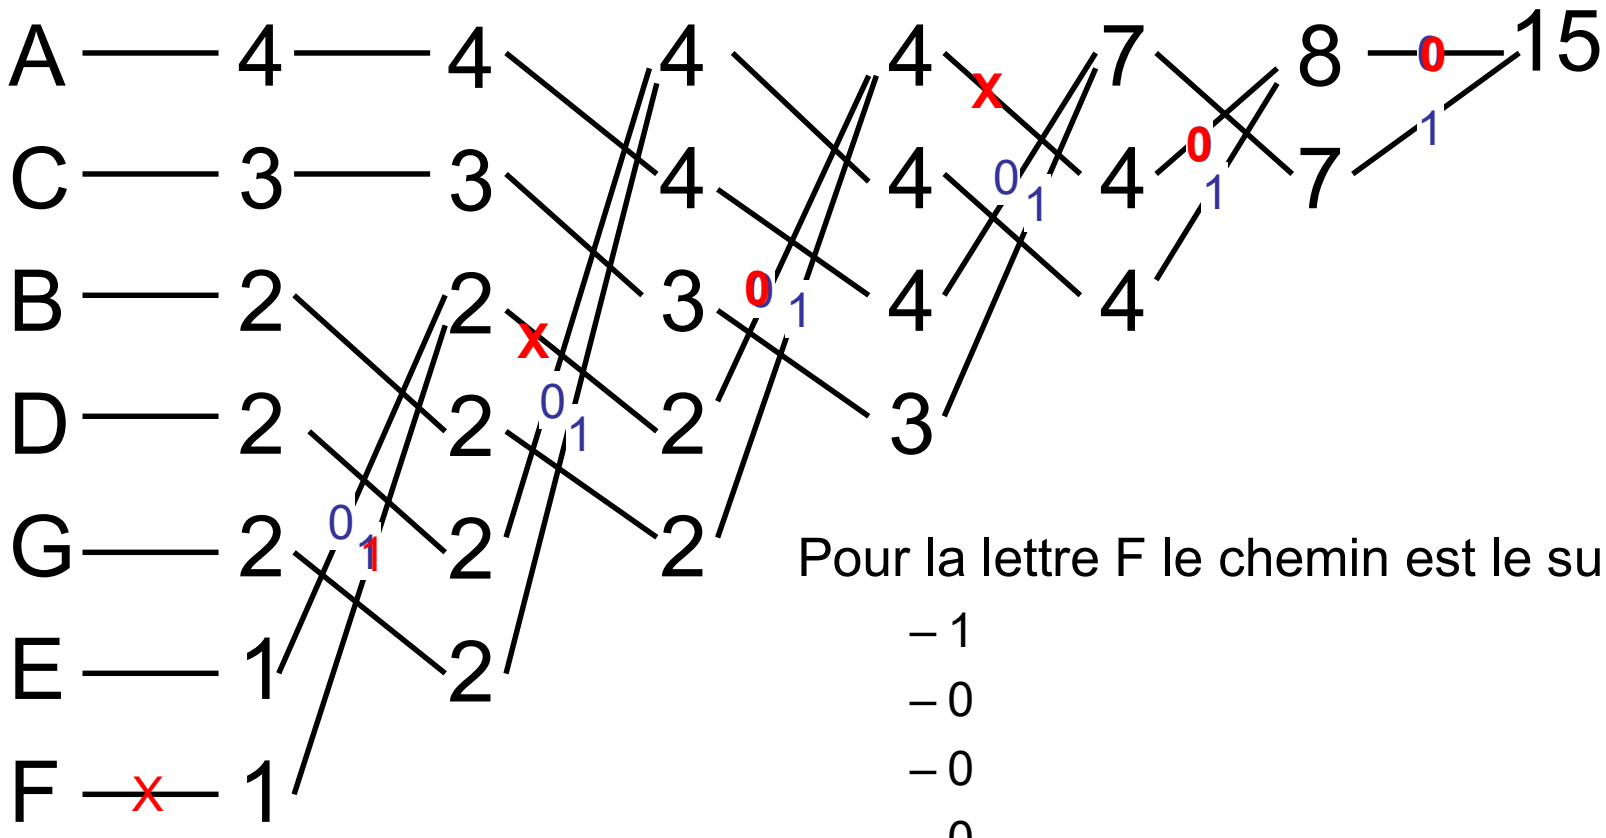


Pour la lettre A le chemin est le suivant :

- 0
- 1

Ce qui donne le code 10

Lecture des codes



Pour la lettre F le chemin est le suivant :

- 1
- 0
- 0
- 0

Ce qui donne le code 0001

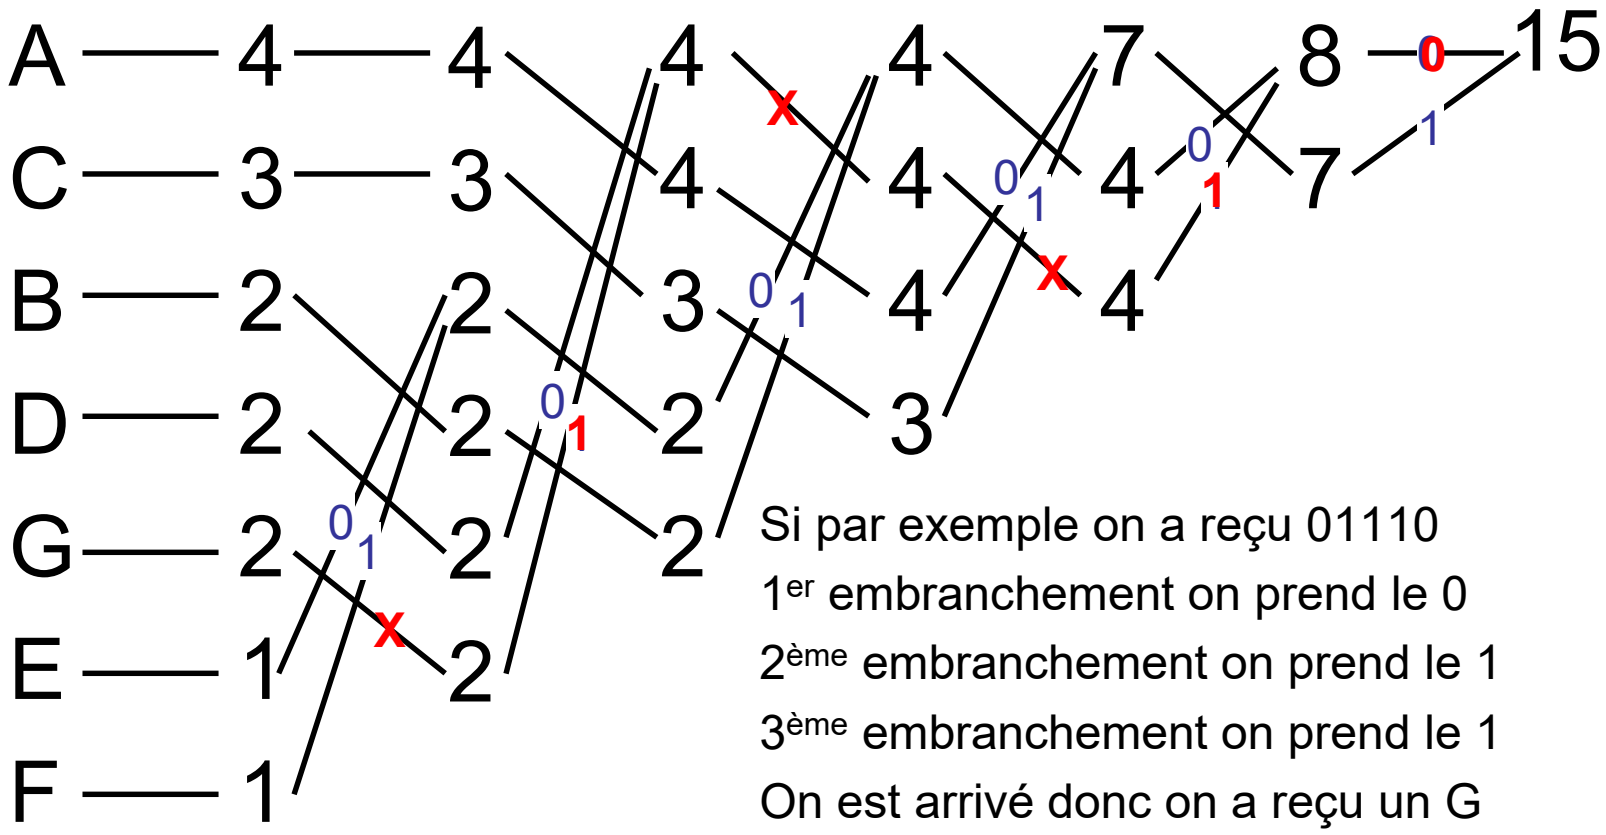
Codes obtenus

- Cette méthode nous donnes des codes courts pour les lettres de forte occurrence :

lettre	occurrences	Code choisi
A	4	10
C	3	11
B	2	001
D	2	010
G	2	011
E	1	0000
F	1	0001

- Les codes obtenus sont séparables en utilisant l'arbre : on part de la racine et chaque fois qu'on trouve un embranchement on lit un bit du code, quand on arrive à une feuille on a décodé une lettre et on repart de la racine.

Décodage



Si par exemple on a reçu 01110

1er embranchement on prend le 0

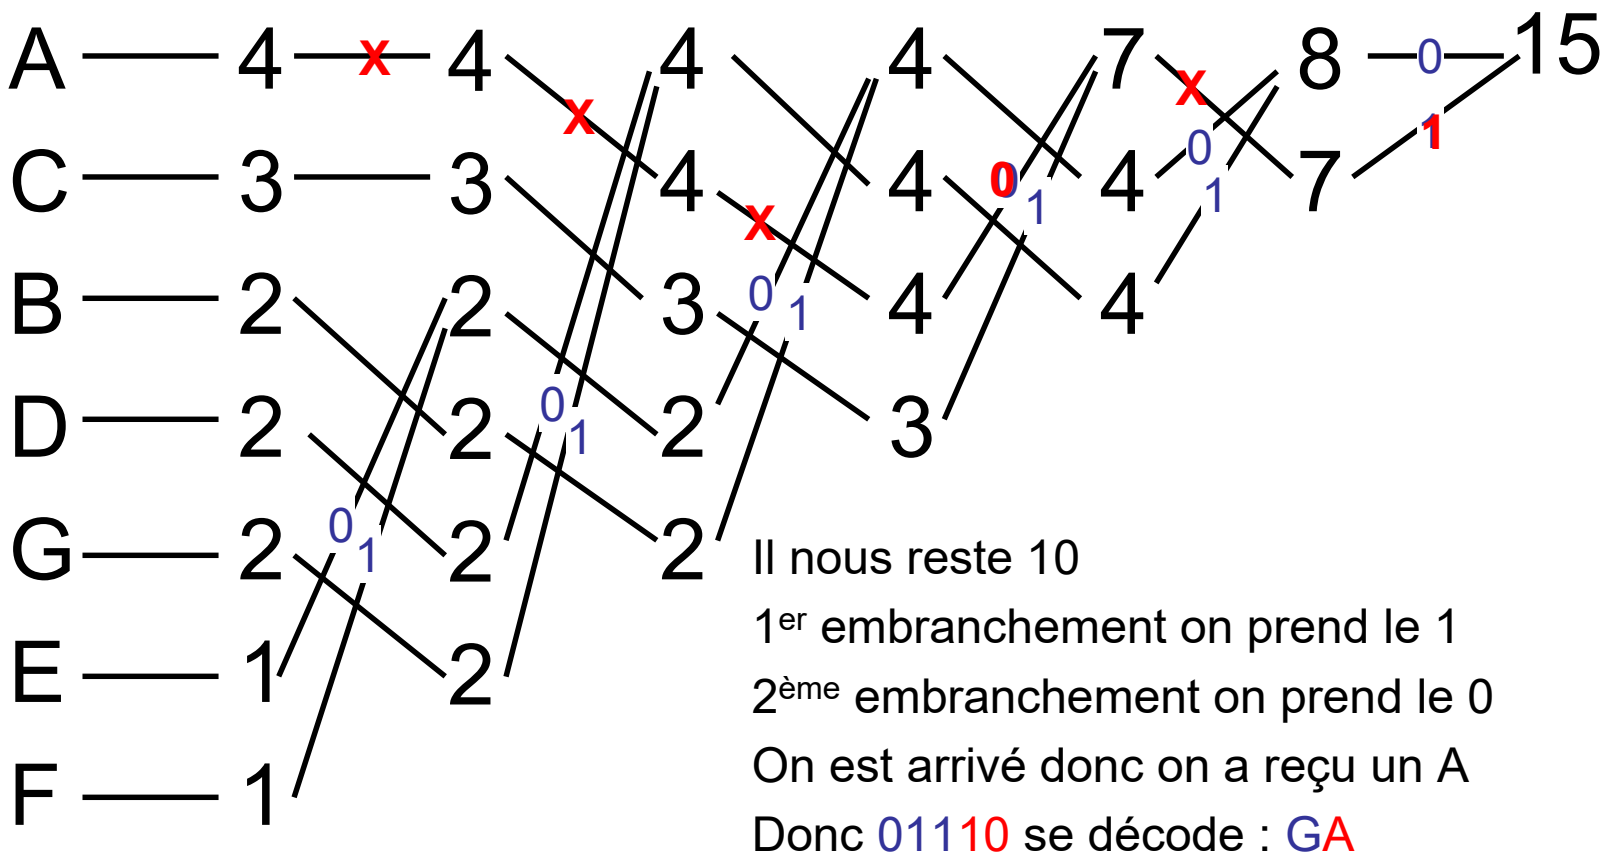
2ème embranchement on prend le 1

3ème embranchement on prend le 1

On est arrivé donc on a reçu un G

Comme on est en fin d'arbre on repart du début

Décodage



Il nous reste 10

1er embranchement on prend le 1

2ème embranchement on prend le 0

On est arrivé donc on a reçu un A

Donc 01110 se décode : GA

Utilisation

Reprenons notre exemple de représentation du nombre 194 796 524 930 401

1. Quelle taille de code obtient-on pour ce nombre en utilisant la méthode de Huffman ?

2. Comparer la taille du mot binaire obtenue
    1. A la taille que nous avions obtenue avec notre code séparable
    2. A la taille avec un codage en format fixe

Compléments

La méthode de Huffman est utilisée par les logiciels de compression (7zip, rar, …)

Mais elle est améliorée en compressant des groupes.

Par exemple dans la chaîne que l'on a compressée : "ABACFGABDDACECG" on peut remarquer que AB apparaît 2 fois donc on aurait pu créer un code pour AB qui aurait été plus court que celui de F qui n'apparaît qu'une fois. On aurait eu aussi un code pour A puisqu'il apparaît ailleurs que dans AB mais on n'en aurait pas eu pour B puisqu'il n'apparaît que 2 fois et toujours dans AB.

Par exemple dans un texte en français on pourra trouver de nombreuses occurrences de "ait", "ais", "ez", etc

Compléments



Certains types de données se prêtent à des méthodes de compression particulières :

- Les images possèdent des zones de même couleur (par exemple un coin de ciel bleu) on peut donc compresser en disant que le pixel bleu se reproduit 45 fois d'affilée.
- On peut même accepter de perdre de la qualité en considérant qu'un bleu est assez proche d'un autre pour considérer que c'est le même.
- La vidéo a la particularité que 2 images successives se ressemblent (sauf changement de plan) donc on peut ne coder que les différences ou les différences avec l'image suivante prévue.
- Mais il faut de temps à autre remettre une image complète sinon on ne pourrait voir une vidéo qu'en commençant au début (problème en streaming).
- Le son a la particularité que 2 échantillons successifs ne sont pas très différents (sinon il serait inaudible) donc on peut ne coder que la différence.
- Etc.